Read, Not Reasoned?

Phân tích can thiệp nhân quả có nhãn chuẩn đối với chuỗi suy luận nhiều bước trên mô hình ngôn ngữ nhỏ

Học viên thực hiện: Nguyễn Nam Hán
Giảng viên hướng dẫn: PGS.TS. Nguyễn Thị Kim Anh

Năm 2026

Nội dung trình bày

1. Bối cảnh, vấn đề và mục tiêu nghiên cứu
2. Phương pháp đo: can thiệp lên chuỗi suy luận với kết quả biết trước
3. Giai đoạn 1. Chẩn đoán: mô hình dùng chuỗi suy luận như thế nào
4. Giai đoạn 2. Can thiệp không cần huấn luyện
5. Giai đoạn 3. Can thiệp bằng tinh chỉnh mô hình
6. Giai đoạn 4. Ứng dụng: giảm hallucination khi trả lời từ tài liệu
7. Tổng hợp, hạn chế và hướng phát triển

Bối cảnh và vấn đề

Bối cảnh

- Chain-of-Thought (CoT): mô hình viết các bước trung gian $Z = (z_1, \ldots, z_k)$ trước khi đưa ra đáp án Y.
- Một chuỗi đúng không bảo đảm đáp án được tính từ chuỗi đó. Mô hình có thể trả lời theo lối tắt và viết chuỗi như phần diễn giải đi kèm (Lanham et al., 2023; Paul et al., 2024).
- Mô hình nhỏ (0.5B đến 8B) được triển khai rộng rãi vì chi phí thấp và chạy được tại chỗ, nhưng ít được phân tích về mặt này.

Vấn đề nghiên cứu

- Các phép đo hiện có (che một bước, lấy mẫu lại) chưa được kiểm chứng trên dữ liệu có kết quả biết trước.
- Chưa tách được hai năng lực: đọc thông tin có sẵn và tự hợp thành thông tin mới.
- Chưa rõ nên can thiệp ở giai đoạn giải mã hay giai đoạn huấn luyện.

Mục tiêu và đóng góp

Mục tiêu

- Xây dựng phép đo mức độ mô hình dùng chuỗi suy luận, kiểm chứng bằng các can thiệp có kết quả biết trước.
- Dùng phép đo đó để chẩn đoán mô hình nhỏ, sau đó tìm vị trí can thiệp hiệu quả.

Đóng góp

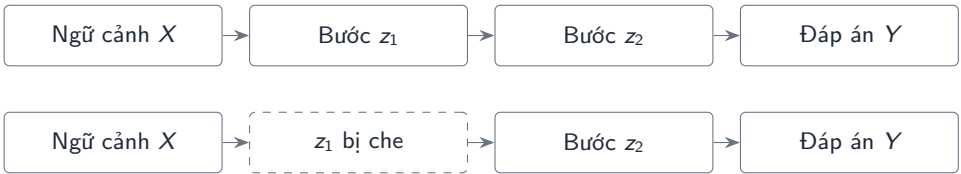
1. **Phương pháp đo.** Chỉ ra hai phép đo phổ biến cho kết quả lệch và cách hiệu chỉnh.
2. **Chẩn đoán.** Mô hình nhỏ đọc đáp án có sẵn trong chuỗi nhưng không dùng chuỗi để hợp thành quan hệ.
3. **Can thiệp.** Can thiệp ở bước giải mã cuối không hiệu quả. Hai cách hiệu quả là giao phép hợp thành cho bộ luật và tinh chỉnh trên chuỗi.
4. **Ứng dụng.** Dữ liệu huấn luyện có tài liệu thiếu bằng chứng và tài liệu mâu thuẫn giúp mô hình biết từ chối và bám theo tài liệu.

Hai loại bài toán suy luận nhiều bước

	Bắc cầu (MuSiQue)	**Hợp thành quan hệ (CLUTRR)**
Ví dụ	Vợ của đạo diễn phim X là ai	Anna có con trai Ben, Ben có chị gái Clara. Clara là gì của Anna
Chuỗi suy luận	Bước 1: đạo diễn phim X là Y. Bước 2: vợ của Y là Z.	Bước 1: Ben là con trai của Anna. Bước 2: Clara là chị gái của Ben.
Đáp án	Z	con gái
Đáp án nằm trong chuỗi	Có, ở bước cuối	Không, phải tính con trai $\circ$ chị gái $=$ con gái
Năng lực cần có	Đọc và chép lại	Hợp thành quan hệ

- So sánh hai loại bài toán cho phép tách việc đọc thông tin có sẵn khỏi việc suy luận thật.

Phương pháp đo: can thiệp lên chuỗi suy luận



- Hiệu ứng của bước z_i là mức giảm xác suất mô hình gán cho đáp án đúng Y^* khi bước đó bị can thiệp:

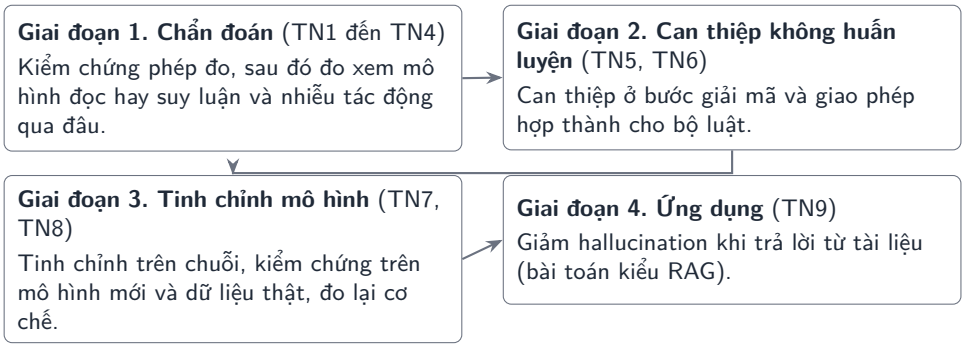
$$\Delta_i = p(Y^* \mid X, Z) - p\big(Y^* \mid X, \mathrm{do}(z_i)\big)$$

- Δ_i lớn: mô hình dựa vào bước z_i khi trả lời. $\Delta_i \approx 0$: mô hình bỏ qua bước đó.
- Kiểm chứng phép đo: chèn vào chuỗi một bước đúng nhưng không liên quan tới câu hỏi. Hiệu ứng thật của bước này bằng 0, nên phép đo đúng phải cho $\Delta \approx 0$.

Dữ liệu, mô hình và giao thức thực nghiệm

Thành phần	Mô tả
CLUTRR	Hợp thành quan hệ gia đình, chuỗi 2 đến 10 bước. Tập kiểm thử gồm câu cùng phân phối, tổ hợp quan hệ mới và chuỗi dài 5 đến 8 bước
MuSiQue	Hỏi đáp bắc cầu 2 đến 4 bước trên Wikipedia, mỗi câu kèm 4 hoặc 8 đoạn nhiễu
2WikiMultihopQA	Hỏi đáp nhiều bước trên Wikipedia, dùng để kiểm tra khả năng tổng quát
Mô hình	Qwen2.5 (0.5B, 1.5B, 3B, 7B), SmolLM2-1.7B, Qwen3 (1.7B, 4B, 8B)
Tài nguyên	2 GPU T4 16 GB (Kaggle)
Giao thức	Giả thuyết và ngưỡng chấp nhận được ghi trước khi chạy. Kết luận dựa trên khoảng tin cậy 95% bằng bootstrap ghép cặp

Lộ trình thực nghiệm



- Kết quả của mỗi giai đoạn quyết định thiết kế của giai đoạn sau.

TN1. Phép che một bước không phát hiện được bước bắc cầu

Giả thuyết. Che riêng một bước giữa (Lanham et al., 2023) cho $\Delta \approx 0$ vì bước cuối vẫn ghi sẵn đáp án.

Thiết kế. Trên MuSiQue so sánh: che riêng một bước ($\mathrm{do}_{\mathrm{naive}}$), che bước và mọi bước phụ thuộc vào nó ($\mathrm{do}_{\mathrm{total}}$), và bỏ toàn bộ chuỗi. Ngữ cảnh X luôn giữ nguyên.

Mô hình	Δ của $\mathrm{do}_{\mathrm{naive}}$	Δ của $\mathrm{do}_{\mathrm{total}}$	Bỏ cả chuỗi	AUROC của $\mathrm{do}_{\mathrm{naive}}$
Qwen2.5-0.5B	-2.4	56.7	52.6	0.57
Qwen2.5-1.5B	0.6	56.9	55.2	0.71
SmolLM2-1.7B	-3.9	66.8	61.0	0.46
Qwen2.5-3B	0.5	49.1	50.6	0.64
Qwen2.5-7B	6.5	41.3	37.7	0.63

Δ tính bằng điểm phần trăm trên các bước giữa. AUROC phân biệt bước giữa với bước không liên quan, 0.5 là ngẫu nhiên.

Kết quả.

- $\mathrm{do}_{\mathrm{naive}}$ cho $\Delta \approx 0$ và AUROC gần mức ngẫu nhiên.
- $\mathrm{do}_{\mathrm{total}}$ xấp xỉ hiệu ứng bỏ cả chuỗi, tức là đo việc đáp án có trong chuỗi, không đo riêng vai trò một bước.

Kết luận. Phép che một bước bị mù với bước bắc cầu. Dù ngữ cảnh có sẵn đáp án, mô hình lấy đáp án từ chuỗi suy luận.

TN2. Phép lấy mẫu lại với mốc cố định thổi phồng bước không liên quan

Giả thuyết. Khi làm nhiễu bước z_j rồi cho mô hình tự viết tiếp, so sánh với mốc chuỗi chuẩn sẽ gán cả bước không liên quan là quan trọng, vì mô hình nhỏ tự viết tiếp thường sai.
Thiết kế. So sánh mốc cố định với mốc hiệu chỉnh theo vị trí: độ chính xác khi mô hình tự viết tiếp từ cùng vị trí mà không bị can thiệp.

Δ trên MuSiQue	**1.5B**	**3B**
Mốc cố định, bước chuẩn	75.7	61.5
Mốc cố định, bước không liên quan	76.3	56.3
Mốc hiệu chỉnh, bước chuẩn	6.4	11.3
Mốc hiệu chỉnh, bước không liên quan	−0.3	4.3

Kết quả.

- Với mốc cố định, bước không liên quan có Δ ngang bước chuẩn.
- Độ lệch xấp xỉ $1 - b(j)$, với $b(j)$ là độ chính xác khi tự viết tiếp, khoảng 22% đến 44%.
- Mốc hiệu chỉnh đưa bước không liên quan về gần 0.

Kết luận. Phép lấy mẫu lại chỉ dùng được khi so với mốc hiệu chỉnh theo vị trí.

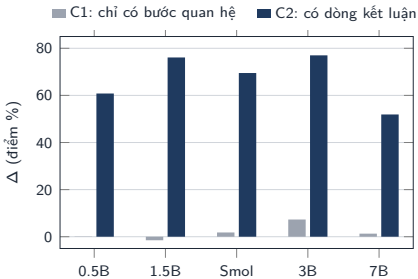
TN3. Thiết kế: phân biệt đọc với suy luận trên CLUTRR

Giả thuyết. Mô hình nhỏ không dùng các bước quan hệ để hợp thành, mà chỉ đọc đáp án khi đáp án được viết sẵn trong chuỗi.

Điều kiện	Chuỗi đưa vào mô hình	Nếu mô hình suy luận	Nếu mô hình chỉ đọc
C1	Chỉ các bước quan hệ, che một bước	Δ lớn	$\Delta \approx 0$
C2	Thêm dòng kết luận đúng ở cuối, ví dụ: Vậy Clara là con gái của Anna	Δ thay đổi ít	Δ lớn, vì mô hình đọc dòng kết luận
C3	Thêm dòng kết luận sai ở cuối, ví dụ: Vậy Clara là mẹ của Anna	Bỏ qua dòng sai	Chép theo dòng sai

- Ở C3, nhãn sai được chọn ngẫu nhiên trong các quan hệ khác của CLUTRR. Mỗi cặp người chỉ có đúng một nhãn đúng, nên mọi nhãn khác đều mâu thuẫn với các bước quan hệ.
- Tỷ lệ chép theo được đo trên cả những câu mà mô hình trả lời đúng khi chuỗi chưa có dòng kết luận.

TN3. Kết quả: mô hình nhỏ đọc chứ không suy luận



C3: tỷ lệ chép theo dòng kết luận sai

Mô hình	Mọi câu	Câu tự giải đúng
Qwen2.5-0.5B	66.5%	70.8%
Qwen2.5-1.5B	58.2%	63.0%
Qwen2.5-3B	46.2%	47.7%
Qwen2.5-7B	22.9%	10.3%

- C1: Δ từ -1.5 đến 7.3 điểm. Mô hình không dùng các bước quan hệ.
- C2: Δ từ 52 đến 77 điểm. Mô hình dựa vào dòng ghi sẵn đáp án.
- C3: mô hình 3B trở xuống ưu tiên dòng kết luận viết sẵn hơn kết quả nó tự tính được. Mô hình 7B ít chép hơn nhưng vẫn không dùng bước quan hệ ở C1.

Kết luận. Khi chưa tinh chỉnh, mô hình nhỏ đọc đáp án có sẵn trong chuỗi nhưng không hợp thành quan hệ từ chuỗi.

TN4. Nhiễu trong ngữ cảnh gây hại thông qua chuỗi suy luận

Giả thuyết. Đoạn nhiễu làm giảm độ chính xác chủ yếu vì làm hỏng chuỗi suy luận, không phải vì tác động trực tiếp lên bước trả lời.
Thiết kế. Phân tích trung gian nhân quả trên MuSiQue (Qwen2.5-3B, 500 câu). Giữ cố định chuỗi sinh từ ngữ cảnh sạch rồi đưa vào ngữ cảnh có nhiễu.

- Hiệu ứng trực tiếp (NDE): thay đổi do nhiễu khi chuỗi được giữ nguyên.
- Hiệu ứng gián tiếp (TIE): thay đổi do nhiễu làm chuỗi thay đổi.

Chế độ trả lời	NDE	TIE
Có chuỗi suy luận (CoT)	−0.6	−5.0
Trả lời trực tiếp	−3.8	−2.0

Kết luận. Khi có chuỗi suy luận, toàn bộ tác hại của nhiễu đi qua chuỗi. Sửa ở bước đọc đáp án sau khi chuỗi đã viết xong không xử lý được nguyên nhân.

TN5. Can thiệp ở bước giải mã không cải thiện kết quả

Giả thuyết. Từ TN3 và TN4, can thiệp lúc giải mã không sửa được lỗi suy luận. Hai phương pháp được kiểm chứng:

- HGCD: tính lại điểm các đáp án ứng viên theo mức phụ thuộc vào từng bước.
- Lọc ngữ cảnh: giữ 4 đoạn có trọng số attention cao nhất trước khi sinh chuỗi.

HGCD, độ chính xác (%)

	CoT	HGCD
CLUTRR, Qwen2.5-1.5B	18.1	18.1
CLUTRR, SmolLM2-1.7B	21.4	21.0
MuSiQue, Qwen2.5-1.5B	20.8	22.5
MuSiQue, SmolLM2-1.7B	15.0	15.8

Lọc ngữ cảnh, MuSiQue, Qwen2.5-3B (EM %)

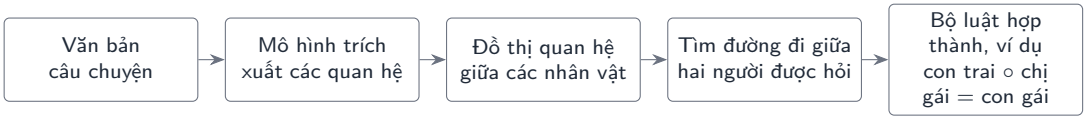
	4 nhiễu	8 nhiễu
CoT	38.8	31.6
Lấy mẫu 5 lần (SC_5)	41.4	35.6
Lọc theo attention	33.8	27.4
Chỉ giữ đoạn chuẩn	48.6	45.6

- HGCD không khác CoT ($|\Delta| \leq 1.7$ điểm, $p \geq 0.6$).
- Lọc theo attention loại nhầm đoạn bắc cầu thứ hai, vì đoạn này chỉ liên quan tới thực thể trung gian chưa xuất hiện trong câu hỏi.

Kết luận. Can thiệp ở bước giải mã không hiệu quả. Cần tác động trực tiếp vào điểm nghẽn mà TN3 chỉ ra là phép hợp thành.

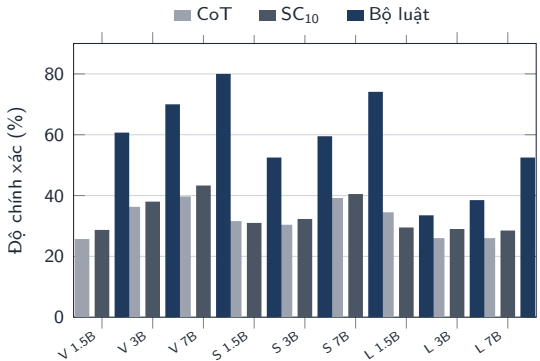
TN6. Giao phép hợp thành cho bộ luật

Giả thuyết. Mô hình trích xuất quan hệ tốt nhưng hợp thành kém (TN3), nên tách hai việc: mô hình trích xuất, bộ luật hợp thành.



- Bộ luật gồm 126 quy tắc, quy nạp tự động từ nhãn của tập huấn luyện.
- So sánh công bằng với lấy mẫu 10 lần (SC_{10}), có chi phí sinh token không nhỏ hơn.
- Thí nghiệm đối chứng: giữ nguyên danh sách quan hệ đã trích xuất, chỉ thay bộ hợp thành (bộ luật hoặc chính mô hình) để tách phần đóng góp của bộ luật.

TN6. Kết quả: bộ luật tăng mạnh độ chính xác



V: cùng phân phối, 2 đến 4 bước. S: tổ hợp quan hệ mới. L: chuỗi dài 5 đến 8 bước.

Kết quả

- Hơn SC_{10} từ 21 đến 37 điểm trên chuỗi 2 đến 4 bước.
- Chuỗi dài: hơn 24 điểm ở 7B, không khác biệt ở 1.5B.
- Đối chứng, cùng danh sách quan hệ: bộ luật hơn chính mô hình từ 13 đến 35 điểm (ví dụ 7B: 71.5% so với 36.1%).

Kết luận. Phần tăng đến từ bộ luật hợp thành, không đến từ bước trích xuất. Cách này hiệu quả nhưng chỉ áp dụng được ở miền có tập quan hệ đóng.

TN7. Tinh chỉnh trên chuỗi suy luận

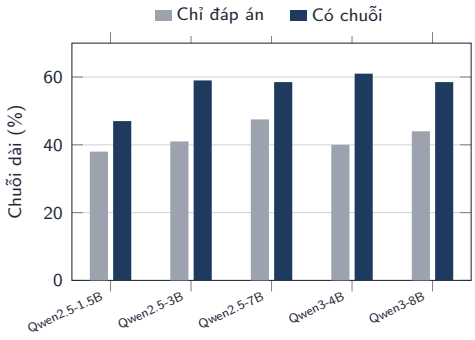
Giả thuyết. Mô hình không hợp thành được do cách gợi ý chứ không do giới hạn năng lực. Tinh chỉnh trên chuỗi sẽ dạy được mô hình tự hợp thành.
Thiết kế.

- LoRA trên 3000 câu CLUTRR, chỉ gồm chuỗi 2 đến 4 bước. Chuỗi huấn luyện được dựng tự động từ đường đi quan hệ.
- Hai dạng dữ liệu: chỉ có đáp án, và có chuỗi các bước trước đáp án.
- Kiểm tra trên tổ hợp quan hệ mới và chuỗi dài 5 đến 8 bước chưa từng thấy khi huấn luyện.

Qwen2.5-3B, độ chính xác (%)	Cùng phân phối	Tổ hợp mới	Chuỗi dài
CoT, không tinh chỉnh	36.3	30.4	26.0
Bộ luật (TN6)	70.0	59.5	38.5
Tinh chỉnh, chỉ đáp án	90.3	55.1	41.0
Tinh chỉnh, có chuỗi	**94.7**	**77.8**	**59.0**

Kết luận. Tinh chỉnh trên chuỗi đưa mô hình 3B từ 36.3% lên 94.7%, và vượt bộ luật trên chuỗi dài.

TN7. Kết quả lặp lại trên mô hình khác và dữ liệu thật



CLUTRR, chuỗi 5 đến 8 bước. Chuỗi hơn chỉ đáp án từ 9 đến 21 điểm.

Mô hình mới có chế độ thinking (Qwen3-4B)

- Chuỗi dài: thinking 22.0%, tinh chỉnh trên chuỗi 61.0%.
- Thinking bị giới hạn 1500 token, nhiều lượt chưa hoàn thành.

Dữ liệu Wikipedia (2WikiMultihopQA, 3B)

- EM: không tinh chỉnh 28.8, chỉ đáp án 50.0, có chuỗi 56.0.
- Huấn luyện trên một loại câu hỏi, kiểm tra trên loại khác: có chuỗi 40.6, chỉ đáp án 22.6.

Kết luận. Tinh chỉnh trên chuỗi là cách hiệu quả nhất trong các phương pháp đã thử. Chuỗi giúp tổng quát sang đề mới, chuỗi dài và loại câu hỏi mới. Mô hình mới hơn chưa thay thế được bước tinh chỉnh này.

TN8. Sau tinh chỉnh, câu trả lời phụ thuộc vào chuỗi

Thiết kế. Đo lại TN3 trên mô hình đã tinh chỉnh (120 câu CLUTRR). Trên CLUTRR đáp án không nằm trong chuỗi, nên phép che không xóa đáp án như ở TN1.

	Hiệu ứng che bước (điểm)		Chép dòng kết luận sai	
Mô hình	**Trước**	**Sau**	**Trước**	**Sau**
Qwen2.5-1.5B	−1.5	36 đến 42	63.0%	13 đến 22%
Qwen2.5-3B	7.3	41 đến 44	47.7%	26 đến 32%
Qwen2.5-7B	1.3	39	10.3%	47.5%

Kết quả

- Hiệu ứng che bước tăng từ mức nhiễu lên khoảng 40 điểm: sau tinh chỉnh, câu trả lời phụ thuộc vào chuỗi.
- Mô hình vẫn tin dòng kết luận cuối. Với 7B, tỷ lệ chép kết luận sai tăng sau tinh chỉnh.
- Huấn luyện thêm bằng DPO với cặp phản thực giảm tỷ lệ chép xuống 4.5% đến 7.2%, nhưng làm giảm 5 đến 13 điểm trên chuỗi dài. GRPO không cải thiện chuỗi dài.

Kết luận. Tinh chỉnh thay đổi cơ chế: mô hình chuyển sang dựa vào chuỗi. DPO và GRPO chỉ cho đánh đổi, không cho cải thiện thêm.

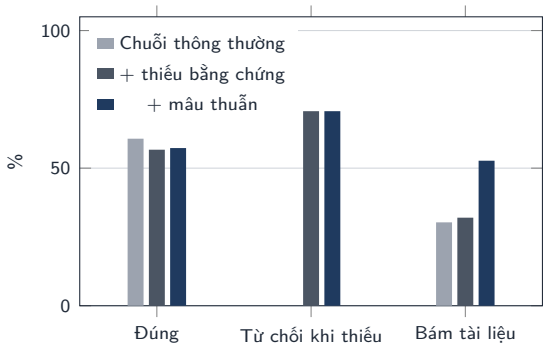
TN9. Giảm hallucination khi trả lời từ tài liệu: thiết kế

Giả thuyết. Huấn luyện thêm trên tài liệu thiếu bằng chứng và tài liệu mâu thuẫn dạy mô hình từ chối khi tài liệu không đủ và bám theo tài liệu khi tài liệu khác với trí nhớ.

Điều kiện	**Can thiệp lên tài liệu (MuSiQue)**	**Hành vi đúng**
Đủ bằng chứng	Giữ nguyên: đoạn bằng chứng và 4 đoạn nhiễu	Trả lời đúng
Thiếu bằng chứng	Bỏ một đoạn bằng chứng	Trả lời không đủ thông tin
Mâu thuẫn	Thay đáp án trong tài liệu bằng một thực thể cùng loại	Trả lời theo tài liệu

- Hành vi đúng được biết trước nhờ can thiệp có kiểm soát, cùng nguyên tắc với TN1 đến TN3.
- Các cách huấn luyện: tinh chỉnh trên chuỗi thông thường, thêm mẫu thiếu bằng chứng, thêm mẫu mâu thuẫn.
- Mô hình: Qwen2.5-3B (2 seed) và Qwen3-4B. Mỗi điều kiện 300 câu.

TN9. Kết quả: mô hình học được cách từ chối và bám tài liệu



Qwen3-4B. Đúng: trên câu đủ bằng chứng. Từ chối khi thiếu: trên câu thiếu bằng chứng. Bám tài liệu: trên câu mâu thuẫn.

Kết quả, lặp lại trên cả 3 lần chạy

- Từ chối khi thiếu bằng chứng tăng từ 0% lên 56% đến 71%.
- Bám tài liệu khi mâu thuẫn tăng 21 đến 24 điểm.
- Độ chính xác trên câu đủ bằng chứng giảm 4 đến 8 điểm, vượt ngưỡng 5 điểm đặt trước ở cả 3 lần chạy.
- DPO và GRPO chỉ dời điểm cân bằng giữa trả lời và từ chối, không cải thiện thật.

Kết luận. Hai loại dữ liệu đơn giản dạy được mô hình từ chối và bám tài liệu. Nguồn lỗi còn lại chủ yếu là độ chính xác gốc (44% đến 61%) trên câu đủ bằng chứng.

Tổng hợp kết quả

TN	Giả thuyết	Kết quả chính	Đánh giá
TN1	Che một bước không thấy bước bắc cầu	$\Delta \approx 0$, AUROC 0.46 đến 0.71	Chấp nhận
TN2	Lấy mẫu lại mốc cố định thổi phồng bước thừa	56 đến 76 điểm, về ≤ 4 sau hiệu chỉnh	Chấp nhận
TN3	Mô hình nhỏ đọc chứ không suy luận	C1 ≈ 0; C2 từ 52 đến 77 điểm	Chấp nhận
TN4	Nhiễu gây hại qua chuỗi	NDE -0.6, TIE -5.0	Chấp nhận
TN5	Can thiệp ở bước giải mã cải thiện kết quả	Không khác CoT	Bác bỏ
TN6	Bộ luật hợp thành cải thiện kết quả	Hơn SC_{10} từ 21 đến 37 điểm	Chấp nhận
TN7	Tinh chỉnh trên chuỗi dạy được hợp thành	3B: 36.3% lên 94.7%; chuỗi hơn đáp án 9 đến 21 điểm	Chấp nhận
TN8	Sau tinh chỉnh mô hình dựa vào chuỗi	Hiệu ứng che bước khoảng 40 điểm	Chấp nhận
TN9	Dữ liệu thiếu bằng chứng và mâu thuẫn giảm hallucination	Từ chối 56% đến 71%; bám tài liệu tăng 21 đến 24 điểm	Chấp nhận một phần

Hạn chế

- Dữ liệu chủ yếu là CLUTRR (tổng hợp) và MuSiQue. Bộ luật ở TN6 chỉ dùng được ở miền có tập quan hệ đóng.
- Mô hình từ 0.5B đến 8B. Chưa kiểm chứng trên mô hình rất lớn như GPT-5 hay Claude Opus.
- Nhiều kết quả chỉ có một seed. Các kết luận chính đã được lặp lại trên nhiều mô hình.
- Trên MuSiQue, phép che toàn phần đo việc đáp án có trong chuỗi, không đo riêng vai trò từng bước. Kết luận về suy luận dựa trên CLUTRR.
- Nhãn thiếu bằng chứng ở TN9 được dựng bằng cách bỏ đoạn văn, mô hình vẫn có thể trả lời từ trí nhớ.

Kết luận và hướng phát triển

Kết luận

1. Phép che một bước và phép lấy mẫu lại với mốc cố định cho kết quả lệch. Cần đối chứng và mốc hiệu chỉnh.
2. Mô hình nhỏ chưa tinh chỉnh đọc đáp án có sẵn trong chuỗi nhưng không dùng chuỗi để hợp thành quan hệ.
3. Can thiệp ở bước giải mã không hiệu quả. Bộ luật hợp thành hiệu quả ở miền đóng. Tinh chỉnh trên chuỗi hiệu quả và tổng quát hơn.
4. Dữ liệu thiếu bằng chứng và mâu thuẫn giúp mô hình từ chối và bám tài liệu khi trả lời từ tài liệu.

Hướng phát triển

- Nâng độ chính xác gốc khi trả lời từ tài liệu bằng dữ liệu chuỗi lớn và đa dạng hơn.
- Kiểm chứng với hệ thống RAG dùng bộ truy xuất thật.
- Áp dụng phép đo cho mô hình lớn qua API.

Xin trân trọng cảm ơn

Kính mong nhận được ý kiến đóng góp của thầy cô

Phụ lục. Tài liệu tham khảo chính

1. Lanham et al. Measuring Faithfulness in Chain-of-Thought Reasoning. arXiv:2307.13702, 2023.
2. Dziri et al. Faith and Fate: Limits of Transformers on Compositionality. NeurIPS 2023.
3. Paul, West, Bosselut, Faltings. Making Reasoning Matter: Measuring and Improving Faithfulness of Chain-of-Thought Reasoning. Findings of EMNLP 2024.
4. Tutek, Hashemi Chaleshtori, Marasović, Belinkov. Measuring Chain of Thought Faithfulness by Unlearning Reasoning Steps. EMNLP 2025.
5. Somov, Chaichuk, Seleznyov, Panchenko, Tutubalina. Breaking the Chain: A Causal Analysis of LLM Faithfulness to Intermediate Structures. arXiv:2603.16475, 2026.

Phụ lục. Mã nguồn và kết quả

Nội dung	Đường dẫn
Giả thuyết đăng ký trước và kết luận từng vòng	`REVIEW.md`
TN1 đến TN3	`results/reliance_v2/`
TN4	`results/mediation_n500/`
TN5, TN6	`results/decoding/`, `results/causaldec/`
TN7, TN8	`results/cftrain/`, `results/cfrl/`, `results/egen/`
TN9	`hgcd/hall.py`, `results/hall/`