Read, Not Reasoned?

Phân tích can thiệp nhân quả có nhãn chuẩn đối với chuỗi suy luận nhiều bước trên mô hình ngôn ngữ nhỏ

Học viên thực hiện: Nguyễn Nam Hán
Giảng viên hướng dẫn: PGS.TS. Nguyễn Thị Kim Anh

Năm 2026

Cấu trúc bài trình bày và ba đóng góp chính

Cấu trúc nội dung

1. Đặt vấn đề và cơ sở lý thuyết
2. Phương pháp luận: mô hình nhân quả cấu trúc (SCM) có nhãn chuẩn
3. Tổng quan các kết quả thực nghiệm
4. Chẩn đoán cơ chế: trích xuất bề mặt và suy diễn hợp thành (R1–R5)
5. Can thiệp ở giai đoạn giải mã (D1–D3)
6. Can thiệp ở giai đoạn huấn luyện: SFT, DPO, GRPO (D4–D9)
7. Hạn chế, thảo luận và hướng phát triển

Ba đóng góp của luận văn

- **Phương pháp đo.** Chỉ ra độ lệch hệ thống của các thước đo tầm quan trọng của bước suy luận hiện có [Lanham et al., 2023; Tutek et al., EMNLP 2025]; đề xuất phép can thiệp toàn phần $\mathrm{do}_{\mathrm{total}}$ được kiểm chuẩn bằng nhãn biết trước, đạt AUROC tới 0.98.
- **Chẩn đoán cơ chế.** Xác lập phát hiện thực nghiệm *"Read, Not Reasoned"* trên mô hình 0.5B–7B và phân rã tác động của nhiễu bằng phân tích trung gian nhân quả [Pearl, 2001; Vig et al., NeurIPS 2020].
- **Vị trí can thiệp.** Cho thấy can thiệp giải mã muộn không hiệu quả trong phạm vi khảo sát; định lượng hiệu quả của thực thi quy tắc lai (Neuro-Symbolic) và của tinh chỉnh SFT/DPO/GRPO.

Đặt vấn đề: tính trung thực nhân quả của chuỗi suy luận

Bối cảnh nghiên cứu

Kỹ thuật **Chain-of-Thought (CoT)** cải thiện hiệu năng suy luận bằng cách sinh chuỗi bước trung gian $Z = (z_1, \ldots, z_k)$ từ ngữ cảnh X trước khi đưa ra đáp án Y. Nhiều nghiên cứu gần đây đặt vấn đề về **tính trung thực (faithfulness)** của Z [Lanham et al., 2023; Turpin et al., NeurIPS 2023; Paul et al., Findings of EMNLP 2024]. Có hai cơ chế đối lập:

1. **Suy diễn nhân quả ($X \to Z \to Y$):** đáp án Y là kết quả tính toán từ các bước z_i; thay đổi z_i kéo theo thay đổi Y.
2. **Hợp thức hóa hậu nghiệm ($X \to Y$):** mô hình dự đoán dựa trên lối tắt thống kê hoặc chỉ sao chép thực thể ở bước cuối, còn Z chỉ là phần diễn giải đi kèm.

Khoảng trống nghiên cứu

- **Thiếu nhãn chuẩn.** Các công trình trước đo tầm quan trọng của z_i trên chuỗi tự sinh nhưng không biết giá trị thực để kiểm chuẩn thước đo. Hướng dùng tác vụ có hàm xác định, trong đó mỗi can thiệp có đúng một kết quả, mới được áp dụng cho cấu trúc trung gian dạng schema [Somov et al., 2026].
- **Chưa tách hai năng lực.** Năng lực *đọc trích xuất* và năng lực *hợp thành quan hệ* thường bị gộp chung [Dziri et al., NeurIPS 2023].
- **Vị trí can thiệp.** Với mô hình nhỏ (0.5B–7B), chưa rõ nên can thiệp ở bước giải mã hay ở bước huấn luyện.

Kết luận thực nghiệm: Luận văn xây dựng khung kiểm định nhân quả có nhãn chuẩn nhằm làm rõ cơ chế vận hành của mô hình ngôn ngữ nhỏ và xác định vị trí can thiệp phù hợp.

Phân loại tác vụ: bắc cầu trích xuất và hợp thành quan hệ

Loại A: bắc cầu trích xuất (MuSiQue)

Câu hỏi: Vợ của đạo diễn bộ phim X là ai?

`Bước 1 (`z_1`): Đạo diễn bộ phim X là Y.`
`Bước 2 (`z_2`): Vợ của Y là Z.`
`Đáp án (`Y`): Z`

- Mỗi bước là một phép truy xuất thực thể từ văn bản.
- Thực thể đích "Z" **xuất hiện tường minh** ở bước cuối z_2, nên khi dự đoán Y mô hình chỉ cần *sao chép bề mặt* từ z_2.

Loại B: hợp thành quan hệ (CLUTRR)

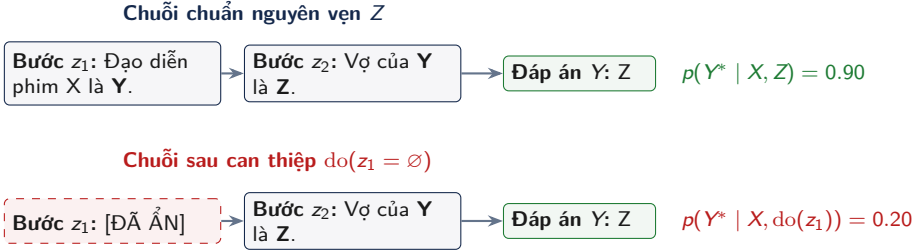
Ngữ cảnh: Anna đưa con trai Ben đi chơi. Ben và chị gái Clara nướng bánh. **Câu hỏi:** Clara là gì của Anna?

`Bước 1 (`z_1`): Ben là con trai của Anna.`
`Bước 2 (`z_2`): Clara là chị gái của Ben.`
`Đáp án (`Y`): con gái`

- Nhãn đáp án "con gái" **không xuất hiện** trong z_1, z_2.
- Để trả lời đúng, mô hình phải thực hiện phép hợp thành quan hệ ẩn:
  $r_1 \circ r_2 =$ con trai $\circ$ chị gái $=$ con gái [Dziri et al., NeurIPS 2023].

Kết luận thực nghiệm: So sánh mức phụ thuộc nhân quả giữa Loại A và Loại B cho phép tách hành vi **trích xuất bề mặt (Read)** khỏi năng lực **suy diễn hợp thành (Reason)**.

Phương pháp đo: can thiệp nhân quả trên đồ thị suy luận (SCM)



Định nghĩa hiệu ứng can thiệp

Gọi Y^* là đáp án chuẩn. Hiệu ứng nhân quả của bước z_i lên dự đoán cuối được định nghĩa bằng mức giảm xác suất:

$$\Delta_i = p(Y^* \mid X, Z) - p\big(Y^* \mid X, \mathrm{do}(z_i = \varnothing)\big)$$

và được biểu diễn theo điểm phần trăm.

Diễn giải

- $\Delta_i \gg 0$: bước z_i là *nguyên nhân thực sự* của Y^* trong quá trình tính toán.
- $\Delta_i \approx 0$: mô hình không sử dụng thông tin tại z_i khi đưa ra Y^*.

Kiểm chuẩn thước đo bằng nhãn chuẩn nhân quả

Hạn chế của các thước đo hiện hành

Các nghiên cứu trước áp dụng phép xóa hoặc làm nhiễu bước suy luận [Lanham et al., 2023; Paul et al., Findings of EMNLP 2024; Tutek et al., EMNLP 2025] nhưng không thể định lượng độ chính xác của chính phép đo vì thiếu nhãn chuẩn. Luận văn áp dụng ý tưởng can thiệp có đáp án xác định [Somov et al., 2026] cho chuỗi suy luận tự do.

Thiết kế kiểm chuẩn có nhãn biết trước

Chuỗi Z được cấu trúc sao cho hiệu ứng nhân quả lý thuyết của từng thành phần đã biết:

Phép biến đổi có kiểm soát	**Nhãn chuẩn lý thuyết**
Chèn bước z_{irr} đúng sự thật nhưng độc lập nhân quả với Y^*	$\Delta_{\text{true}}(z_{\text{irr}}) = 0$
Bước chuẩn z_{gold} nằm trên đường đi ngắn nhất tới Y^*	$\Delta_{\text{true}}(z_{\text{gold}}) > 0$
Biến đổi bảo toàn cấu trúc (đổi tên thực thể)	$\Delta_{\text{true}} = 0$

Minh họa phép thử bước dư thừa (z_{irr})

```
Bước 1 (z_gold): Ben là con trai của Anna.
Bước 2 (z_gold): Clara là chị gái của Ben.
Bước 3 (z_irr): Anna thích môn bóng đá.
```

Thước đo nào gán $\Delta(z_{\text{irr}}) \gg 0$ đều mắc **sai số dương tính giả**.

Đánh giá định lượng bằng AUROC

Xét bài toán phân loại nhị phân giữa tập bước thiết yếu $\{z_{\text{gold}}\}$ và tập bước dư thừa $\{z_{\text{irr}}\}$ dựa trên điểm Δ:

$$\text{AUROC} = \Pr\left(\Delta(z_{\text{gold}}) > \Delta(z_{\text{irr}})\right)$$

Thước đo lý tưởng đạt AUROC $\to 1.0$; thước đo không có thông tin đạt 0.5.

Thiết lập thực nghiệm, bộ dữ liệu và giao thức kiểm định

Bộ dữ liệu và mô hình khảo sát

Thành phần	Đặc tả kỹ thuật
CLUTRR	Suy luận hợp thành quan hệ (độ dài $k \in [2, 10]$); 11.708 mẫu huấn luyện; tập kiểm thử cùng phân phối (ID) và ngoài phân phối (OOD).
MuSiQue-Ans	Hỏi đáp bắc cầu 2–4 bước trên Wikipedia; ngữ cảnh gồm các đoạn chuẩn trộn với 4 hoặc 8 đoạn nhiễu.
2WikiMultihopQA	Hỏi đáp dạng Compositional và Inference trên văn bản Wikipedia tự nhiên.
Mô hình (SLM)	Qwen2.5 (0.5B, 1.5B, 3B, 7B) [Qwen Team, 2024] và SmolLM2-1.7B.
Tài nguyên tính toán	GPU 16GB VRAM (môi trường triển khai hạn chế tài nguyên).

Giao thức kiểm định thống kê

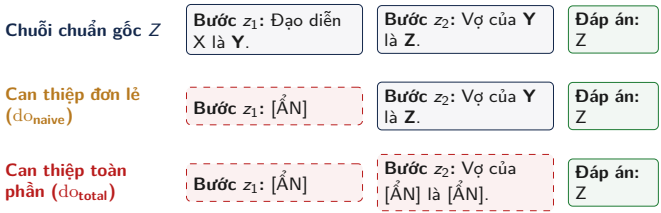
- **Tiền đăng ký giả thuyết.** Ngưỡng chấp nhận của mỗi phương pháp được ghi trong biên bản thiết kế trước khi đánh giá trên tập kiểm thử.
- **Tiêu chuẩn bác bỏ H_0.** Phương pháp đề xuất phải vượt đường cơ sở mạnh nhất tối thiểu $+2.0$ điểm tuyệt đối, với khoảng tin cậy 95% (paired bootstrap) không chứa giá trị 0.
- **Đối chứng cùng chi phí.** Phương pháp giải mã tốn k lượt chạy được so sánh với Self-Consistency (SC_k) có cùng ngân sách sinh token.

Tổng quan kết quả thực nghiệm (R1–R5 và D1–D9)

Mã	Giả thuyết / phương pháp can thiệp	Kết quả định lượng chính	Kiểm định
R1	Phép che đơn lẻ ($\mathrm{do}_{\mathrm{naive}}$) bỏ sót phụ thuộc bắc cầu; phép che toàn phần ($\mathrm{do}_{\mathrm{total}}$) khắc phục được	$\mathrm{do}_{\mathrm{naive}}$: -4 đến $+6.5$; $\mathrm{do}_{\mathrm{total}}$: 41–67 điểm	XÁC NHẬN
R2	Lấy mẫu lại với mốc cố định gán nhầm bước dư thừa là quan trọng	Bước thừa: 56–78 điểm; sau hiệu chỉnh: ≤ 4	XÁC NHẬN
R3	**Mô hình nhỏ trích xuất bề mặt thay vì suy diễn hợp thành**	CLUTRR: -1.5 đến $+7.3$; có đáp án: 52–77	XÁC NHẬN
R4	Nhiễu ngữ cảnh làm giảm hiệu năng gián tiếp qua việc làm hỏng chuỗi CoT (TIE)	NDE ≈ 0; TIE $= -3.6$ đến -5.0	XÁC NHẬN
R5	Tái trọng số giải mã tại bước kết xuất đáp án (HGCD) cải thiện độ chính xác	$\lvert\Delta\rvert \leq 1.7$, $p \geq 0.6$ so với CoT	BÁC BỎ
D1	Lọc đoạn văn nhiễu bằng điểm Attention trước khi sinh chuỗi (MuSiQue)	Thấp hơn SC_5; làm mất đoạn bắc cầu	BÁC BỎ
D2	Giao phép hợp thành cho bộ giải quy tắc (Neuro-Symbolic Extract + Rules)	Vượt SC_{10} cùng chi phí $+21$ đến $+37$ điểm	XÁC NHẬN
D3	Ablation: cố định sự kiện đầu vào, cô lập vai trò của bộ hợp thành	Bảng luật vượt LLM $+13$ đến $+35$ điểm	XÁC NHẬN
D4	SFT trên chuỗi chuẩn so với chuỗi ghi trạng thái quan hệ tích lũy	SFT chuẩn (3B): 95/78/59%; cấu trúc: -3 đến -7	BÁC BỎ (cấu trúc)
D5	SFT trên văn bản tự nhiên (2WikiMultihopQA) kèm nhãn trích dẫn nguồn	SFT $+21$ đến $+30$ so với few-shot; nguồn: -1.6	ĐÁNH ĐỔI
D6	SFT hình thành sự phụ thuộc nhân quả vào các bước trung gian	$\Delta(\mathrm{do}_{\mathrm{total}})$ tăng từ 1–7 lên $\sim$40 điểm; chép sai 13–48%	XÁC NHẬN
D7	Sinh chuỗi sau SFT tổng quát hóa ngoài phân phối tốt hơn dự đoán trực tiếp	Có chuỗi hơn chỉ đáp án $+9$ đến $+23$ điểm (OOD)	XÁC NHẬN
D8	DPO phản thực giảm hành vi chép kết luận sai	Chép sai giảm 22–25 điểm; chuỗi dài giảm 5–13 điểm	ĐÁNH ĐỔI
D9	GRPO với phần thưởng kiểm chứng theo từng bước	Chuỗi dài $+0.0$; lật đáp án giảm từ 36% xuống 22%	ĐÁNH ĐỔI

R1–R4 là các giả thuyết chẩn đoán nhân quả; R5 và D1–D9 là các phương pháp can thiệp nhằm nâng hiệu năng.

R1 · Phép che đơn lẻ ($\mathrm{do}_{\mathrm{naive}}$) và can thiệp toàn phần ($\mathrm{do}_{\mathrm{total}}$)



Phân tích trên đồ thị suy luận có hướng (DRG)

Trong chuỗi bắc cầu $z_1 \to z_2 \to Y$, thực thể trung gian $e_1 =$ "Y" là đầu ra của z_1 và được dùng lại làm đầu vào của z_2.

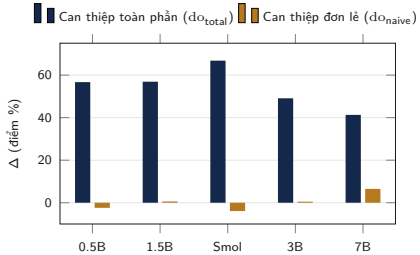
- Khi che đơn lẻ $\mathrm{do}_{\mathrm{naive}}(z_1)$ [Lanham et al., 2023], thực thể e_1 và kết quả $e_2 =$ "Z" vẫn còn nguyên trong z_2.
- Cơ chế attention của mô hình tự hồi quy đọc thẳng z_2 để xuất đáp án, nên $\Delta_{\mathrm{naive}}(z_1) \approx 0$ (sai số âm tính giả).

Đề xuất toán tử can thiệp toàn phần ($\mathrm{do}_{\mathrm{total}}$)

Dựng đồ thị suy luận có hướng $\mathcal{G} = (V, E)$, trong đó cạnh $(i \to j) \in E$ tồn tại nếu thực thể kết quả của bước z_i xuất hiện trong tiền đề của bước z_j.

Phép can thiệp toàn phần $\mathrm{do}_{\mathrm{total}}(z_i)$ che đồng thời z_i và toàn bộ tập đỉnh hậu duệ $\mathrm{desc}_{\mathcal{G}}(i)$ trên $\mathcal{G}$, nhờ đó cắt đứt mọi đường truyền thông tin từ z_i tới đáp án.

R1 · Kết quả: $\mathrm{do}_{\mathrm{total}}$ khôi phục tầm quan trọng của bước trung gian



Dữ liệu: MuSiQue (đánh giá trên các bước chuẩn không phải bước cuối).

Khả năng phân biệt bước chuẩn và bước dư thừa (AUROC)

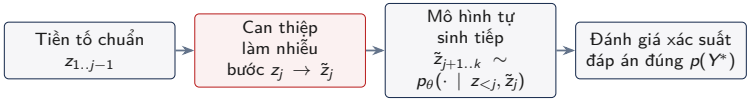
Mô hình	AUROC ($\mathrm{do}_{\mathrm{total}}$)	AUROC ($\mathrm{do}_{\mathrm{naive}}$)
Qwen2.5-1.5B	**0.98**	0.82
Qwen2.5-3B	**0.97**	0.76
Qwen2.5-7B	**0.86**	0.71

Đối chứng giả dược định dạng (marker control):

Chèn cùng số token `[ẨN]` vào vị trí tương ứng nhưng *giữ nguyên chuỗi thực thể cầu nối* chỉ làm Δ biến thiên 0.0–7.0 điểm. Do đó hiệu ứng 41–67 điểm của $\mathrm{do}_{\mathrm{total}}$ đến từ việc cắt đứt dòng thông tin nhân quả, không phải từ thay đổi định dạng.

Kết luận thực nghiệm: Phép che đơn lẻ $\mathrm{do}_{\mathrm{naive}}$ gần như không phát hiện được vai trò của các bước trung gian ($\Delta \in [-3.9, +6.5]$). Toán tử $\mathrm{do}_{\mathrm{total}}$ khắc phục rò rỉ thông tin hạ lưu và đạt AUROC tới 0.98. XÁC NHẬN

R2 · Độ lệch đường cơ sở của phương pháp lấy mẫu lại



Dẫn xuất độ lệch

Lấy mẫu lại là hướng được đề xuất để diễn giải chuỗi suy luận [Bogdan et al., 2025; Macar et al., ICLR 2026]. Phiên bản dùng mốc cố định so sánh với chuỗi chuẩn hoàn hảo $p(Y^* \mid Z_{\text{gold}}) \approx 1$:

$$\Delta_{\text{fixed}}(j) = p(Y^* \mid Z_{\text{gold}}) - \mathbb{E}_{\tilde{z}_{>j}}\left[p(Y^* \mid z_{<j}, \tilde{z}_j, \tilde{z}_{>j})\right]$$

Ngay cả khi $\tilde{z}_j = z_j$ hoặc z_j là bước dư thừa, mô hình nhỏ khi tự sinh tiếp $\tilde{z}_{>j}$ chỉ đạt độ chính xác cơ sở $b(j) \in [22\%, 44\%]$. Vì vậy $\Delta_{\text{fixed}}(j)$ bị cộng thêm sai số dương tính giả xấp xỉ $1 - b(j) \approx 56\%$–78%.

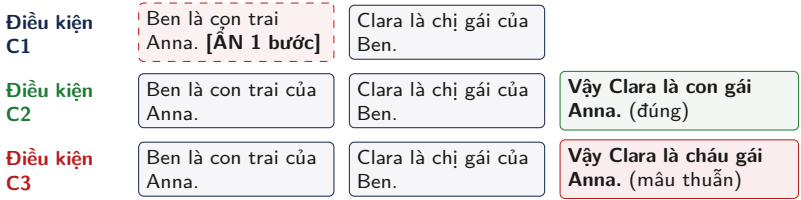
Kết quả sau hiệu chỉnh theo vị trí

Định nghĩa $\Delta_{\text{cal}}(j) = b(j) - \mathbb{E}_{\tilde{z}_{>j}}[p(Y^* \mid z_{<j}, \tilde{z}_j, \tilde{z}_{>j})]$:

Điểm Δ trên MuSiQue	**1.5B**	**3B**
Δ_{fixed} (mốc cố định): bước chuẩn	75.7	61.5
Δ_{fixed} (mốc cố định): **bước dư thừa**	**76.3**	**56.3**
Δ_{cal} (có hiệu chỉnh): bước chuẩn	**6.4**	**11.3**
Δ_{cal} (có hiệu chỉnh): **bước dư thừa**	**−0.3**	**4.3**

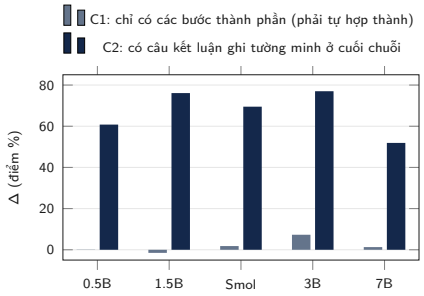
Kết luận thực nghiệm: Mốc cố định gán nhầm mọi bước dư thừa thành bước quan trọng (56–76 điểm). Hiệu chỉnh đường cơ sở theo vị trí $b(j)$ loại bỏ phần lớn độ lệch này. **XÁC NHẬN**

R3 · Thiết kế kiểm định: trích xuất bề mặt và suy diễn hợp thành



Điều kiện	Cấu hình chuỗi trên CLUTRR	Dự đoán của giả thuyết suy diễn (H_{reason})	Dự đoán của giả thuyết đọc bề mặt (H_{read})
C1 (do_{total})	Chuỗi chỉ chứa các bước quan hệ thành phần; ẩn 1 bước	$\Delta \gg 0$: mất một mắt xích làm thay đổi kết quả hợp thành	$\Delta \approx 0$: mô hình vốn không tính được phép hợp thành từ các bước này
C2 (explicit)	Bổ sung câu kết luận *đúng* vào cuối chuỗi	Câu kết luận dư thừa, hiệu ứng che thay đổi ít	$\Delta \gg 0$: mô hình chuyển sang đọc trực tiếp nhãn quan hệ vừa được viết ra
C3 (conflict)	Bổ sung câu kết luận *sai*, mâu thuẫn với các bước trên	Bác bỏ câu sai vì mâu thuẫn với phép hợp thành $r_1 \circ r_2$	Sao chép nhãn sai ($T_{\text{copy-wrong}} \gg 0$) do ưu tiên vị trí cuối

R3 · Kết quả: xác nhận “Read, Not Reasoned” trên mô hình nhỏ



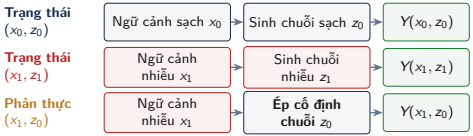
Điều kiện C3: tỷ lệ sao chép kết luận mâu thuẫn ($T_{\text{copy-wrong}}$)

Mô hình	Toàn tập	Tập mô hình tự giải đúng
Qwen2.5-0.5B	66.5%	70.8%
Qwen2.5-1.5B	58.2%	63.0%
Qwen2.5-3B	46.2%	47.7%
Qwen2.5-7B	22.9%	**10.3%**

Phân tích:
Với các mô hình $\leq$ 3B, ngay cả trên tập con câu hỏi mà mô hình *tự giải đúng từ chuỗi C1*, việc chèn thêm một câu kết luận sai khiến mô hình sao chép theo trong 47.7%–70.8% trường hợp.

Kết luận thực nghiệm: Khi chưa tinh chỉnh, mô hình nhỏ hầu như không thực hiện phép hợp thành trên chuỗi ($\Delta_{C1} \in [-1.5, +7.3]$) và chỉ phụ thuộc vào chuỗi khi đáp án xuất hiện trên bề mặt văn bản ($\Delta_{C2} \in [51.9, 77.0]$). **XÁC NHẬN**

R4 · Phân tích trung gian nhân quả: tác động của nhiễu qua chuỗi



Phân rã hiệu ứng trực tiếp và gián tiếp [Pearl, 2001; Vig et al., NeurIPS 2020]

- **Hiệu ứng trực tiếp (NDE):** $\mathbb{E}[Y(x_1, z_0) - Y(x_0, z_0)]$, tức tác hại của đoạn nhiễu khi giữ nguyên chuỗi sạch z_0.
- **Hiệu ứng gián tiếp (TIE):** $\mathbb{E}[Y(x_1, z_1) - Y(x_1, z_0)]$, tức tác hại do nhiễu làm suy giảm chất lượng chuỗi z_1.

Qwen2.5-3B (MuSiQue, $n = 500$)	**NDE**	**TIE**
Giải mã có chuỗi suy luận (CoT)	-0.6	$\mathbf{-5.0}$
Dự đoán trực tiếp (direct prompting)	-3.8	-2.0

Hệ quả đối với thiết kế can thiệp

- Ở chế độ CoT, NDE $= -0.6$ (không khác 0 có ý nghĩa thống kê): chuỗi Z đóng vai trò **nút thắt thông tin**, che bước dự đoán cuối khỏi ngữ cảnh X.
- Phần suy giảm hiệu năng còn lại nằm ở TIE $= -5.0$: đoạn văn nhiễu làm chệch quá trình sinh chuỗi từ z_0 sang z_1.

Kết luận thực nghiệm: Vì tác hại của nhiễu truyền qua biến trung gian Z (TIE), can thiệp chỉ chỉnh sửa bước đọc đáp án sau khi Z đã sinh xong không xử lý được nguyên nhân gốc. XÁC NHẬN

R5 · Can thiệp giải mã tại bước kết xuất đáp án (HGCD) không hiệu quả

Giải mã tương phản neo theo bước (HGCD)

Sau khi sinh chuỗi Z, các đáp án ứng viên y được tái trọng số theo mức phụ thuộc nhân quả của chúng vào các bước z_i:

$$\text{Score}_{\text{HGCD}}(y) = \log p_\theta(y \mid X, Z) + \alpha \sum_{i=1}^{k} \Delta_i(y)$$

Độ chính xác (%)	CoT	HGCD	Calibration
CLUTRR, Qwen2.5-1.5B	18.1	18.1	23.9
CLUTRR, SmolLM2-1.7B	21.4	21.0	24.8
MuSiQue, Qwen2.5-1.5B	20.8	22.5	–
MuSiQue, SmolLM2-1.7B	15.0	15.8	–

Giải thích dựa trên R3 và R4

Việc HGCD không cải thiện ($|\Delta| \leq 1.7$ điểm, $p \geq 0.6$) phù hợp với hai phát hiện trước:

1. **Trên CLUTRR (từ R3).** Mô hình không thực hiện phép hợp thành nên $\Delta_i(y) \approx 0$ với mọi ứng viên y; tổng $\sum_i \Delta_i(y)$ chỉ chứa nhiễu ngẫu nhiên và không đổi được thứ hạng xác suất.
2. **Trên MuSiQue (từ R4).** Khi mô hình trả lời sai, nguyên nhân thường là chuỗi Z đã truy xuất sai thực thể cầu nối (thành phần TIE). Tái trọng số trên một chuỗi đã sai không thể khôi phục đáp án đúng.

Kết luận thực nghiệm: Trong phạm vi khảo sát, can thiệp giải mã muộn không sửa được lỗi suy luận nhiều bước: điều chỉnh phân phối token ở bước đọc cuối không thay thế được việc sửa chuỗi hoặc sửa phép hợp thành. **BÁC BỎ**

D1 · Lọc đoạn văn nhiễu bằng attention trước khi sinh chuỗi

Ngữ cảnh X gồm 8 đoạn văn (Đoạn 2 và Đoạn 5 là bằng chứng bắc cầu BẮT BUỘC):



Giữ $K = 4$ đoạn có tổng trọng số attention từ câu hỏi cao nhất ⇒ **bỏ sót Đoạn 5 (bước bắc cầu thứ hai)**:



Số nhiễu	Mô hình	CoT	SC_5	Top-4	Xếp lại	Oracle
4 đoạn	Qwen-1.5B	24.8	**28.4**	23.6	23.0	34.8
4 đoạn	Qwen-3B	38.8	**41.4**	33.8	37.4	48.6
8 đoạn	Qwen-1.5B	22.2	**25.0**	22.0	22.2	31.4
8 đoạn	Qwen-3B	31.6	**35.6**	27.4	33.6	45.6

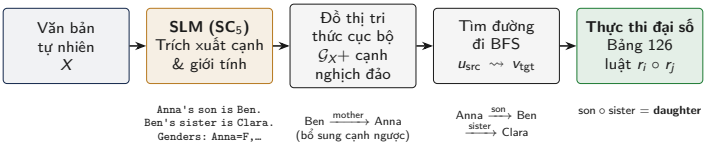
Chỉ số Exact Match (EM, %), $n = 500$. Oracle: chỉ giữ các đoạn chuẩn (trần lý thuyết).

Phân tích điểm nghẽn truy xuất đa bước

- Khoảng cách giữa Oracle và CoT (+9 đến +14 điểm) phù hợp với R4: loại bỏ nhiễu đầu vào giúp chất lượng sinh chuỗi tăng đáng kể.
- Tuy nhiên, đoạn bắc cầu thứ hai (Đoạn 5) chỉ liên quan tới thực thể trung gian e_1 chưa xuất hiện trong câu hỏi, nên có điểm attention trực tiếp từ câu hỏi thấp.
- Độ phủ (Recall@4) chỉ đạt 77%–86%; việc cắt mất đoạn chuẩn thứ hai khiến nhánh Top-4 thấp hơn CoT.

Kết luận thực nghiệm: Trọng số attention trước khi sinh chuỗi của mô hình nhỏ không nhận diện được đoạn bắc cầu ẩn; phương pháp lấy mẫu nhiều chuỗi SC_5 vẫn tốt hơn. BÁC BỎ

D2 · Kiến trúc lai Neuro-Symbolic: tách trích xuất và hợp thành



Nguyên lý thiết kế từ chẩn đoán nhân quả

Tác vụ hợp thành được mô tả bởi hai hàm:

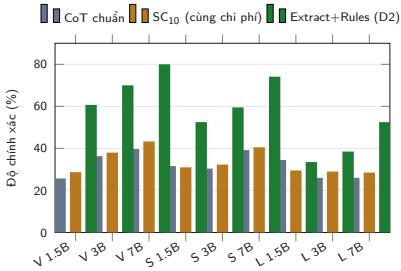
$$E = f_{\text{extract}}(X), \qquad Y = f_{\text{compose}}(E)$$

R3 cho thấy mô hình nhỏ thực hiện được f_{extract} (đọc bề mặt) nhưng không thực hiện được f_{compose} [Dziri et al., NeurIPS 2023]. Theo hướng các hệ thống Neuro-Symbolic [Olausson et al., EMNLP 2023; Lyu et al., IJCNLP-AACL 2023], f_{extract} được giao cho mô hình ngôn ngữ còn f_{compose} được thực thi bằng bộ giải đại số quan hệ tất định. Hướng này cũng phù hợp với quan sát gần đây rằng khi quyết định cuối được tính bằng công cụ ngoài từ cấu trúc trung gian thì hiện tượng không cập nhật theo can thiệp giảm đáng kể [Somov et al., 2026].

Thiết lập so sánh cùng chi phí

- Bảng 126 luật hợp thành $r_1 \circ r_2 \to r_3$ được quy nạp tự động từ nhãn tập huấn luyện (chính xác 95% trên chuỗi chuẩn).
- SC_5 được dùng để bỏ phiếu đa số trên tập cạnh trích xuất; nếu đồ thị $\mathcal{G}_X$ không nối được hai thực thể đích, hệ thống dùng dự đoán CoT.
- Đối chứng trực tiếp với SC_{10}, có tổng số token sinh ra không nhỏ hơn toàn bộ pipeline D2.

D2 · Kết quả: vượt Self-Consistency cùng chi phí +21 đến +37 điểm



V: tập validation (2–4 bước); S: cấu trúc mới OOD (2–4 bước); L: chuỗi dài OOD (**5–8 bước**).

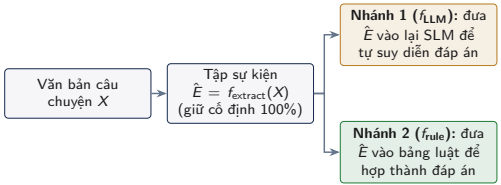
Chênh lệch hiệu năng (D2 − SC_{10})

Tập	Quy mô	Δ [KTC 95%]
V (ID)	1.5B / 3B / 7B	+32.0 / +32.0 / +36.7
S (OOD)	1.5B / 3B / 7B	+20.9 / +27.2 / +33.5
L (5–8)	Qwen2.5-1.5B	−1.0 (không có ý nghĩa)
L (5–8)	Qwen2.5-3B	+9.5 [3.5, 15.5]
L (5–8)	Qwen2.5-7B	+**24.0** [17.0, 31.5]

- Trên chuỗi ngắn (2–4 bước), D2 tăng gấp đôi độ chính xác ở mọi kích thước mô hình.
- Trên chuỗi dài OOD (5–8 bước), mức cải thiện tăng theo khả năng trích xuất đủ các cạnh của mô hình nền (+24.0 điểm ở 7B).

Kết luận thực nghiệm: Giao phép hợp thành cho bộ giải quy tắc giúp mô hình 1.5B (60.7%) vượt mô hình 7B chạy Self-Consistency 10 mẫu (43.3%) trên tập validation. XÁC NHẬN

D3 · Ablation: cô lập vai trò của bộ hợp thành



Kiểm soát biến gây nhiễu

Một giải thích thay thế cho kết quả của D2 là bước trích xuất $\hat{E}$ đã tóm tắt và loại các câu nhiễu trong câu chuyện X, nên độ chính xác tăng không phải nhờ bộ hợp thành.

Để kiểm tra, ta giữ nguyên đầu ra trích xuất $\hat{E}$ cho từng mẫu và chỉ thay hàm hợp thành: $f_{\text{LLM}}(\hat{E})$ so với $f_{\text{rule}}(\hat{E})$.

Độ dài	Mô hình	CoT	Nhánh 1	Nhánh 2	N2 − N1
2–4 bước	Qwen-1.5B	31.6	32.9	**46.2**	+13.3
	Qwen-3B	30.4	28.5	**54.4**	+25.9
	Qwen-7B	39.2	36.1	**71.5**	+35.4
5–8 bước	Qwen-1.5B	34.5	29.0	33.0	+4.0 (n.s.)
	Qwen-3B	26.0	27.0	32.0	+5.0 (n.s.)
	Qwen-7B	26.0	33.0	**46.0**	+13.0

Kết luận thực nghiệm: Khi đã có sẵn danh sách sự kiện sạch $\hat{E}$, bản thân mô hình ngôn ngữ (Nhánh 1) không cải thiện so với CoT. Thay bước hợp thành bằng bảng luật (Nhánh 2) cho mức tăng +13 đến +35 điểm trên chuỗi ngắn. XÁC NHẬN

D4 · SFT: thiết kế ba định dạng chuỗi giám sát

1. Chỉ đáp án (answer-only)

```
Đáp án: Clara là con gái của Anna.
```

Mô hình học ánh xạ trực tiếp $X \to Y$ trong không gian ẩn, không có chuỗi trung gian Z.

2. Chuỗi chuẩn tự nhiên (S_plain)

```
Bước 1: Ben là con trai của Anna.
Bước 2: Clara là chị gái của Ben.
Đáp án: Clara là con gái của Anna.
```

Liệt kê các cạnh quan hệ trên đường đi, hợp thành ở dòng cuối.

3. Chuỗi trạng thái tích lũy (S_struct)

```
Bước 1: Ben là con trai của Anna.
→ Tích lũy: Ben là con trai Anna.
Bước 2: Clara là chị gái của Ben.
→ Tích lũy: Clara là con gái Anna.
Đáp án: Clara là con gái của Anna.
```

Mục tiêu nghiên cứu

Khi không dùng bộ giải quy tắc ngoài như D2, tinh chỉnh có giám sát (LoRA SFT trên 3.000 mẫu có độ dài **chỉ từ 2–4 bước**) có giúp mô hình nhỏ nội tâm hóa phép hợp thành $r_1 \circ r_2$ hay không.

Giả thuyết về định dạng cấu trúc (S_struct)

Nhánh `S_struct` yêu cầu mô hình ghi tường minh kết quả hợp thành trung gian sau mỗi bước, tức đưa bài toán chuỗi dài về chuỗi các phép hợp thành hai bước. Giả thuyết là định dạng này giúp tổng quát hóa sang chuỗi **5–8 bước** tốt hơn `S_plain`.

D4 · Kết quả SFT: chuỗi chuẩn hình thành năng lực hợp thành

Độ chính xác (%) sau khi huấn luyện trên mẫu 2–4 bước

SLM	Phương pháp	Val 2–4	OOD 2–4	OOD 5–8
3B	CoT (few-shot)	36.3	30.4	26.0
3B	D2: Extract+Rules	70.0	59.5	38.5
3B	Prompt cấu trúc	28.3	27.9	23.5
3B	**SFT chuỗi chuẩn (S_plain)**	**94.7**	**77.8**	**59.0**
3B	SFT cấu trúc (S_struct)	89.3	72.2	52.5
1.5B	**SFT chuỗi chuẩn (S_plain)**	**83.0**	**60.1**	**47.0**
1.5B	SFT cấu trúc (S_struct)	83.3	60.8	42.5

Số liệu seed 0; seed 1 nhất quán (3B S_plain: 94.7 / 74.7 / 58.5).

Hai phát hiện chính

1. **Cấu trúc phụ trợ không cải thiện.** Trên tập OOD 5–8 bước, S_struct − S_plain = −6.5 điểm (seed 0) và −3.0 điểm (seed 1). Chuỗi dài hơn có thể làm tăng tích lũy lỗi tự hồi quy.
2. **SFT chuỗi chuẩn hiệu quả.** Chỉ với 3.000 mẫu ngắn (2–4 bước), `S_plain` đưa mô hình 3B từ 36.3% lên **94.7**% (ID) và đạt **59.0**% trên chuỗi 5–8 bước, cao hơn kiến trúc lai D2 (38.5%) vì không phụ thuộc vào độ phủ của bước trích xuất đồ thị.

Kết luận thực nghiệm: Việc mô hình không hợp thành được quan hệ ở R3 phản ánh hạn chế của cách gợi ý (prompting) chứ không phải giới hạn dung lượng của mô hình; tinh chỉnh trên chuỗi chuẩn `S_plain` khắc phục hạn chế này. **BÁC BỎ** (cấu trúc)

D5 · Kiểm chứng SFT trên văn bản Wikipedia (2WikiMultihopQA)

Thiết lập thực nghiệm trên dữ liệu mở

Để kiểm tra kết luận ở D4 có bị giới hạn trong miền bán tổng hợp (CLUTRR) hay không, SFT được thực hiện trên **2WikiMultihopQA** (nhóm câu hỏi *Compositional* và *Inference*).

Ví dụ chuỗi huấn luyện được dựng từ bằng chứng chuẩn:

```
Hỏi: Ông nội của Charles Bretagne Marie là ai?
Bước 1: Cha của Charles là Jean. [Đoạn: Charles... ]
Bước 2: Cha của Jean là Charles Armand. [Đoạn: Jean...]
Đáp án: Charles Armand René de La Trémoille
```

Bốn nhánh được so sánh: **few-shot**, **SFT chỉ đáp án**, **SFT chuỗi chuẩn** và **SFT chuỗi kèm trích dẫn nguồn**.

Exact Match (%) trên 500 mẫu kiểm thử

Cấu hình	Few-shot	Đáp án	Chuỗi	+Nguồn
Qwen2.5-1.5B (tổng)	21.6	49.8	51.2	**52.4**
Qwen2.5-3B (tổng)	28.8	50.0	**56.0**	54.4
3B, nhóm Inference (91)	7.7	34.1	**41.8**	40.7
3B, nhóm Compositional (409)	33.5	53.5	**59.2**	57.5

- **Hiệu ứng SFT:** tăng $+21$ đến $+30$ điểm EM so với few-shot (3B: $+25.6$ [20.4, 30.6]).
- **Vai trò của chuỗi:** ở 3B, sinh chuỗi hơn chỉ đáp án $+6.0$ [2.0, 10.0] điểm, rõ nhất ở nhóm *Inference*.
- **Trích dẫn nguồn:** độ chính xác trích dẫn 93%–95% nhưng không cải thiện EM của đáp án cuối (-1.6 điểm ở 3B).

Kết luận thực nghiệm: Quy luật trên văn bản Wikipedia tự nhiên nhất quán với CLUTRR: tinh chỉnh có giám sát trên chuỗi chuẩn là yếu tố quyết định hiệu năng, còn việc gắn nhãn trích dẫn không đem lại lợi ích bổ sung. ĐÁNH ĐỔI

D6 · Sau SFT: phụ thuộc nhân quả vào các bước trung gian

Đo lại độ phụ thuộc nhân quả ($\mathrm{do}_{\mathrm{total}}$) sau SFT

Phép thử của R3 được áp dụng lại cho mô hình `S_plain` trên 120 mẫu kiểm thử độc lập:

	Hiệu ứng che bước Δ		Chép sai $T_{\text{copy-wrong}}$	
SLM	**Trước SFT**	**Sau SFT**	**Trước SFT**	**Sau SFT**
1.5B	-1.5	**36.0–42.0**	63.0%	13.0–22.0%
3B	7.3	**41.0–44.0**	47.7%	26.0–32.0%
7B	1.3	**39.0**	10.3%	**47.5%**

Nhận xét

- **Chuyển dịch cơ chế:** $\Delta(\mathrm{do}_{\mathrm{total}})$ tăng từ mức nhiễu (1–7 điểm) lên $\sim$ **40 điểm**, nghĩa là mô hình sau SFT *sử dụng các bước trung gian* để tính đáp án.
- **Tác dụng phụ:** mô hình 7B sau SFT sao chép kết luận sai nhiều hơn (47.5% so với 10.3%), cho thấy nó tin vào dòng kết luận cuối theo quy ước định dạng.

Kết luận thực nghiệm: SFT biến chuỗi CoT từ phần diễn giải đi kèm thành mạch tính toán có phụ thuộc nhân quả ($\Delta \approx 40$ điểm); đồng thời làm xuất hiện xu hướng tin vào dòng kết luận cuối ở mô hình 7B. **XÁC NHẬN**

D7 · Vai trò của chuỗi đối với tổng quát hóa ngoài phân phối

SFT chỉ đáp án (Ans) so với SFT chuỗi chuẩn (Chain), độ chính xác %

	ID (2–4)		OOD (2–4)		OOD (5–8)	
SLM	**Ans**	**Chain**	**Ans**	**Chain**	**Ans**	**Chain**
1.5B	77.7	**83.0**	54.4	**60.1**	38.0	**47.0**
3B	90.3	**94.7**	55.1	**77.8**	41.0	**59.0**
7B	95.0	**95.0**	63.9	**81.0**	47.5	**58.5**

Nhận xét

- Trên tập cùng phân phối, học thẳng đáp án đạt 90.3%–95.0% do ghi nhớ các ánh xạ quen thuộc.
- Với tổ hợp quan hệ mới hoặc chuỗi dài 5–8 bước, nhánh chỉ đáp án giảm mạnh; nhánh sinh chuỗi hơn từ $+\mathbf{9.0}$ đến $+\mathbf{22.7}$ điểm.

Kết luận thực nghiệm: Việc sinh chuỗi trung gian đi cùng với khả năng tổng quát hóa tốt hơn ngoài phân phối so với chỉ học đáp án ($+9$ đến $+23$ điểm). **XÁC NHẬN**

D8 · DPO phản thực giảm hành vi sao chép kết luận sai

Thiết kế

Để xử lý hiện tượng sao chép kết luận sai ở D6, DPO được huấn luyện trên 1.500 cặp đối chiếu ($Z_{\text{chosen}}, Z_{\text{rejected}}$). Mẫu bị từ chối chứa các bước tiền đề đúng nhưng gắn kết luận cuối mâu thuẫn. Hướng dùng phản hồi phản thực để hình thành suy luận cũng được khảo sát trong [Hüyük et al., ICLR 2025].

Nhận xét

- DPO giảm mạnh hành vi sao chép kết luận sai (22–25 điểm, còn 4.5%–7.2%).
- Đổi lại, độ chính xác trên chuỗi dài OOD 5–8 bước giảm 5–13 điểm.

Kết quả trên Qwen2.5-3B

	Chép sai $T_{\text{copy-wrong}}$		OOD 5–8 bước (%)	
	Trước DPO	Sau DPO	Trước DPO	Sau DPO
Seed 0	26.7%	**4.5%**	57.5	44.5
Seed 1	32.4%	**7.2%**	56.5	51.5

Kết luận thực nghiệm: DPO phản thực loại bỏ phần lớn hành vi sao chép kết luận sai nhưng làm giảm độ chính xác trên chuỗi dài; đây là một đánh đổi chứ không phải cải thiện thuần. **ĐÁNH ĐỔI**

D9 · GRPO với phần thưởng theo từng bước

Thiết kế

GRPO [Shao et al., 2024; DeepSeek-AI, 2025] được áp dụng với phần thưởng kiểm chứng được: $+1.0$ cho đáp án đúng và $+0.3\times$ (tỷ lệ bước khớp đồ thị chuẩn).

Một hướng liên quan là thưởng theo mức cần thiết của từng bước [arXiv:2603.22816, 2026]. Luận văn không dùng hướng này vì phép che đơn lẻ không đo được vai trò của bước trung gian (R1).

Nhận xét

- GRPO tăng $+8.9$ điểm trên OOD 2–4 bước (1.5B) và giảm gần một nửa tỷ lệ lật đáp án khi chèn câu nhiễu.
- Chuỗi 5–8 bước chưa cải thiện vì tập huấn luyện RL chỉ gồm mẫu 2–4 bước, nơi mô hình SFT đã giải đúng khoảng 90% nên tín hiệu phương sai trong nhóm thưa.

Độ chính xác (%) và tỷ lệ lật đáp án do nhiễu

SLM	Phương pháp	ID	OOD 2–4	OOD 5–8	Lật do nhiễu
1.5B	Chỉ SFT	84.3	59.5	47.0	51.9%
1.5B	SFT + GRPO	**89.7**	**68.4**	**48.5**	**23.4%**
3B	Chỉ SFT	94.7	77.8	60.0	36.1%
3B	SFT + GRPO	**96.0**	**81.0**	60.0	**22.2%**

Kết luận thực nghiệm: GRPO tăng độ bền trước nhiễu ngữ cảnh (51.9% → 23.4% ở 1.5B) và cải thiện chuỗi ngắn, nhưng chưa cải thiện chuỗi dài 5–8 bước. ĐÁNH ĐỔI

Thảo luận: phạm vi hiệu lực, hạn chế và tính minh bạch

Giới hạn phạm vi và các mối đe dọa tới tính giá trị

1. **Đặc thù miền bài toán.** Bảng luật trong D2 hiệu quả nhất ở các miền có không gian quan hệ đóng (như CLUTRR). Trên văn bản mở (2WikiMultihopQA), hướng SFT (D5) khả thi và tổng quát hơn.
2. **Độ phủ của đồ thị suy luận tự động (DRG).** Thuật toán nối cạnh dựa trên đối sánh thực thể bề mặt hiện chỉ đạt đồ thị liên thông đầy đủ trên 25%–36% chuỗi sinh tự do; các trường hợp đồng tham chiếu ẩn cần mô hình phân giải thực thể mạnh hơn.
3. **Quy mô và miền tác vụ.** Các kết luận được xác lập cho mô hình 0.5B–7B trên suy luận quan hệ và hỏi đáp đa bước; cần kiểm chứng thêm trên suy luận toán học hình thức và mô hình lớn hơn 14B. Phần lớn kết quả dùng một seed.

Nhật ký hiệu chỉnh khi mở rộng cỡ mẫu

Mọi kết quả âm tính và hiệu chỉnh đều được báo cáo:

Giả thuyết / quan sát sơ bộ	**Kết luận sau kiểm chứng quy mô lớn**
Nhiễu làm CoT giảm $\sim 10\%$ ở thử nghiệm thăm dò ($n = 120$)	Với $n = 500$: mức giảm thực tế ổn định ở 3%–6%.
"CoT nhạy cảm với nhiễu hơn dự đoán trực tiếp"	Khoảng tin cậy 95% giao nhau; không đủ bằng chứng cho sự khác biệt.
Hiệu chỉnh tiên nghiệm (calibration) như một phương pháp độc lập	Tương đương giải mã tự do; chỉ dùng làm đường cơ sở.
Lược bỏ giới tính khi trích xuất sự kiện giúp tăng +6%–8%	Phân tích hậu nghiệm không lặp lại được trên tập độc lập; giữ bản gốc.

Kết luận chung và định hướng phát triển

Tổng kết các đóng góp đã kiểm chứng

1. **Chuẩn hóa phép đo nhân quả CoT (R1, R2).** Phép che đơn lẻ ($\mathrm{do}_{\mathrm{naive}}$) và lấy mẫu lại với mốc cố định cho kết quả lệch hệ thống; toán tử che toàn phần ($\mathrm{do}_{\mathrm{total}}$) và hiệu chỉnh theo vị trí đạt AUROC $= 0.86$–0.98.
2. **Giải mã cơ chế của mô hình nhỏ (R3, R4, R5).** Khi chưa tinh chỉnh, mô hình chủ yếu *trích xuất bề mặt* thay vì *suy diễn hợp thành*; nhiễu tác động gián tiếp qua quá trình sinh chuỗi (TIE), nên can thiệp giải mã muộn (HGCD) không hiệu quả.
3. **Hai lộ trình can thiệp hiệu quả (D2–D9).**
   - *Không huấn luyện:* tách trích xuất và hợp thành bằng kiến trúc lai Neuro-Symbolic (D2, D3), tăng $+21$–37 điểm so với SC_{10}.
   - *Có huấn luyện:* SFT trên chuỗi chuẩn (D4–D7) hình thành mạch suy diễn có phụ thuộc nhân quả ($\Delta \approx 40$), tổng quát hóa vượt độ dài ($+9$–23 điểm OOD); DPO/GRPO bổ sung độ bền vững với đánh đổi đã nêu.

Định hướng nghiên cứu tiếp theo

#	Nội dung triển khai
1	**Tối ưu đa mục tiêu DPO + GRPO.** Đưa mẫu chuỗi dài (5–8 bước) vào tập huấn luyện RL/DPO để giảm hành vi chép sai mà không làm giảm hiệu năng OOD.
2	**Đồ thị suy luận ngữ nghĩa (Semantic DRG).** Thay phép so khớp chuỗi trong $\mathrm{do}_{\mathrm{total}}$ bằng mô hình nhúng thực thể để tăng độ phủ liên thông trên văn bản tự do.
3	**Mở rộng quy mô và miền tác vụ.** Áp dụng bộ công cụ kiểm định nhân quả ($\mathrm{do}_{\mathrm{total}}$, $T_{\text{copy-wrong}}$) cho các mô hình suy luận chuyên biệt (14B–32B) trên bài toán toán học và lập trình.

Kết luận thực nghiệm: Chẩn đoán nhân quả giúp xác định đúng vị trí can thiệp: thay vì điều chỉnh ở bước chọn token cuối, cần tác động vào điểm nghẽn hợp thành quan hệ.

XIN TRÂN TRỌNG CẢM ƠN!

Kính mong nhận được ý kiến đóng góp của Quý Thầy Cô trong Hội đồng

Học viên: Nguyễn Nam Hán · GVHD: PGS.TS. Nguyễn Thị Kim Anh

Phụ lục · Tài liệu tham khảo chính

Tính trung thực và phép đo nhân quả của CoT

- Lanham et al. *Measuring Faithfulness in Chain-of-Thought Reasoning*. arXiv:2307.13702, 2023.
- Turpin, Michael, Perez, Bowman. *Language Models Don't Always Say What They Think: Unfaithful Explanations in Chain-of-Thought Prompting*. NeurIPS 2023.
- Paul, West, Bosselut, Faltings. *Making Reasoning Matter: Measuring and Improving Faithfulness of Chain-of-Thought Reasoning*. Findings of EMNLP 2024.
- Tutek, Hashemi Chaleshtori, Marasović, Belinkov. *Measuring Chain of Thought Faithfulness by Unlearning Reasoning Steps*. EMNLP 2025.
- Bogdan, Macar, Nanda, Conmy. *Thought Anchors: Which LLM Reasoning Steps Matter?* arXiv:2506.19143, 2025.
- Macar, Bogdan, Rajamanoharan, Nanda. *Thought Branches: Interpreting LLM Reasoning Requires Resampling*. ICLR 2026.
- Somov, Chaichuk, Seleznyov, Panchenko, Tutubalina. *Breaking the Chain: A Causal Analysis of LLM Faithfulness to Intermediate Structures*. arXiv:2603.16475, 2026.
- *Measuring and Curing Reasoning Rigidity: From Decorative Chain-of-Thought to Genuine Faithfulness*. arXiv:2603.22816, 2026.

Suy diễn hợp thành, Neuro-Symbolic, huấn luyện và nền tảng

- Dziri et al. *Faith and Fate: Limits of Transformers on Compositionality*. NeurIPS 2023.
- Olausson et al. *LINC: A Neurosymbolic Approach for Logical Reasoning by Combining Language Models with First-Order Logic Provers*. EMNLP 2023.
- Lyu et al. *Faithful Chain-of-Thought Reasoning*. IJCNLP-AACL 2023.
- Pearl. *Direct and Indirect Effects*. UAI 2001.
- Vig et al. *Investigating Gender Bias in Language Models Using Causal Mediation Analysis*. NeurIPS 2020.
- Hüyük et al. *Reasoning Elicitation in Language Models via Counterfactual Feedback*. ICLR 2025.
- Shao et al. *DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models* (GRPO). arXiv:2402.03300, 2024.
- DeepSeek-AI. *DeepSeek-R1: Incentivizing Reasoning Capability in LLMs via Reinforcement Learning*. arXiv:2501.12948, 2025.
- Qwen Team. *Qwen2.5 Technical Report*. arXiv:2412.15115, 2024.

Phụ lục · Bảng ký hiệu toán học

X, Z, Y	Ngữ cảnh đầu vào, chuỗi suy luận $Z = (z_1, \ldots, z_k)$ và đáp án.
$\mathcal{G} = (V, E)$	Đồ thị suy luận có hướng (Directed Reasoning Graph, DRG).
$\mathrm{do}_{\text{naive}}(z_i)$	Phép can thiệp che đơn lẻ bước z_i.
$\mathrm{do}_{\text{total}}(z_i)$	Phép can thiệp che toàn phần z_i cùng tập hậu duệ $\mathrm{desc}_{\mathcal{G}}(i)$.
TE, NDE, TIE	Hiệu ứng nhân quả tổng, trực tiếp và gián tiếp qua chuỗi.
$T_{\text{copy-wrong}}$	Tỷ lệ sao chép kết luận sai mâu thuẫn với tiền đề.
SC_k	Self-Consistency với k chuỗi lấy mẫu độc lập.
ID / OOD	Đánh giá cùng phân phối / ngoài phân phối huấn luyện.

Phụ lục · Cấu trúc mã nguồn và dữ liệu thực nghiệm tái lập

Hạng mục nghiên cứu	Đường dẫn trong kho mã nguồn (repository)
Bản thảo bài báo tiếng Anh	`paper/main.pdf`
Báo cáo toàn văn tiếng Việt	`paper/baocao_vi.pdf`
Biên bản tiền đăng ký giả thuyết	`REVIEW.md`
Thực nghiệm R1–R3 (độ phụ thuộc chuỗi, kiểm chuẩn AUROC)	`results/reliance_v2/`
Thực nghiệm R4 (phân tích trung gian nhân quả, $n = 500$)	`results/mediation_n500/`
Thực nghiệm R5 (giải mã tương phản HGCD)	`results/decoding/`
Thực nghiệm D1–D3 (giải mã nhân quả, kiến trúc lai D2)	`results/causaldec/` (C4, C5, C6, C7_ablate, M_select*)
Thực nghiệm D4, D6–D9 (SFT, DPO, GRPO trên CLUTRR)	`hgcd/cftrain.py`, `hgcd/cfrl.py`, `results/cftrain/`, `results/cfrl/`
Thực nghiệm D5 (SFT mở rộng trên 2WikiMultihopQA)	`hgcd/egen.py`, `results/egen/`
Tài liệu thiết kế và biên bản thực nghiệm	`docs/research_notes.md`