Read, Not Reasoned?

Phân tích can thiệp nhân quả có nhãn chuẩn đối với chuỗi suy luận nhiều bước trên mô hình ngôn ngữ nhỏ

Học viên thực hiện: Nguyễn Nam Hán
Giảng viên hướng dẫn: PGS.TS. Nguyễn Thị Kim Anh

Năm 2026

Nội dung trình bày

1. Bối cảnh, vấn đề, mục tiêu và giả thuyết nghiên cứu
2. Phương pháp đo: intervention lên chuỗi suy luận với ground truth biết trước
3. Giai đoạn 1. Chẩn đoán: mô hình dùng Chain-of-Thought như thế nào
4. Giai đoạn 2. Can thiệp không cần huấn luyện
5. Giai đoạn 3. Can thiệp bằng fine-tuning
6. Giai đoạn 4. Ứng dụng: giảm hallucination khi trả lời từ tài liệu (RAG)
7. Tổng hợp, hạn chế và hướng phát triển

Bối cảnh và vấn đề

Bối cảnh

- Chain-of-Thought (CoT): mô hình viết các bước trung gian $Z = (z_1, \ldots, z_k)$ trước khi đưa ra đáp án Y.
- Một chuỗi đúng không bảo đảm đáp án được tính từ chuỗi đó. Mô hình có thể trả lời theo lối tắt, còn chuỗi chỉ là phần diễn giải đi kèm (vấn đề faithfulness; Lanham et al., 2023; Paul et al., 2024).
- Mô hình nhỏ (0.5B đến 8B) được triển khai rộng rãi vì chi phí thấp và chạy được tại chỗ, nhưng ít được phân tích về mặt này.

Vấn đề nghiên cứu

- Các phép đo hiện có (masking một bước, resampling) chưa được kiểm chứng trên dữ liệu có ground truth.
- Chưa tách được hai năng lực: đọc thông tin có sẵn trong chuỗi và tự thực hiện composition để tạo thông tin mới.
- Chưa rõ nên can thiệp ở giai đoạn decoding hay giai đoạn huấn luyện.

Mục tiêu và đóng góp

Mục tiêu

- Xây dựng phép đo mức độ mô hình dùng chuỗi suy luận, kiểm chứng bằng các intervention có ground truth.
- Dùng phép đo đó để chẩn đoán mô hình nhỏ, sau đó tìm vị trí can thiệp hiệu quả.

Đóng góp

1. **Phương pháp đo.** Chỉ ra hai phép đo phổ biến cho kết quả lệch, kèm các control và cách hiệu chỉnh.
2. **Chẩn đoán.** Mô hình nhỏ đọc đáp án có sẵn trong chuỗi nhưng không dùng chuỗi để thực hiện composition.
3. **Can thiệp.** Can thiệp ở bước decoding cuối không hiệu quả. Hai cách hiệu quả: chuyển composition sang rule table, và fine-tuning trên chuỗi.
4. **Ứng dụng.** Dữ liệu huấn luyện có tài liệu thiếu bằng chứng và tài liệu mâu thuẫn giúp mô hình biết abstain và bám theo tài liệu.

Giả thuyết nghiên cứu

Mã	Giả thuyết	Kiểm chứng ở
H1	Các phép đo tầm quan trọng của bước suy luận đang dùng (masking một bước, resampling) cho kết quả lệch khi đối chiếu với ground truth.	TN1, TN2
H2	Mô hình nhỏ chưa fine-tune dùng chuỗi suy luận như nơi đọc đáp án, không như nơi tính ra đáp án.	TN3, TN4
H3	Điểm nghẽn nằm ở composition, nên can thiệp ở bước decoding cuối không hiệu quả còn can thiệp vào composition thì hiệu quả.	TN5 đến TN8
H4	Cùng nguyên tắc intervention có ground truth áp dụng được cho bài toán thực tế: giảm hallucination khi trả lời từ tài liệu.	TN9

Hai loại bài toán suy luận nhiều bước

	Bridge (MuSiQue)	**Composition (CLUTRR)**
Câu hỏi	Vợ của đạo diễn phim X là ai	Anna có con trai Ben, Ben có chị gái Clara. Clara là gì của Anna
Chuỗi suy luận	Hop 1: đạo diễn phim X là Y Hop 2: vợ của Y là Z	Hop 1: con trai của Anna là Ben Hop 2: chị gái của Ben là Clara
Đáp án	Z	con gái (daughter)
Đáp án có trong chuỗi	Có, ở hop cuối	Không, phải tính son $\circ$ sister $=$ daughter
Năng lực cần có	Đọc và chép lại	Composition quan hệ

- Nếu mô hình chỉ đọc, nó sẽ phụ thuộc mạnh vào chuỗi ở MuSiQue và gần như không phụ thuộc ở CLUTRR. So sánh hai loại bài toán cho phép tách việc đọc khỏi việc suy luận.

Phương pháp đo: intervention lên chuỗi suy luận

Cách đo. Không cho mô hình sinh lại. Đưa vào mô hình một prompt cố định gồm ngữ cảnh X, chuỗi Z (đã sửa hoặc chưa sửa) và dòng `Answer:`, rồi đọc xác suất mô hình gán cho đáp án đúng.

$$\Delta_i = p(Y^* \mid X, Z) - p(Y^* \mid X, \mathrm{do}(z_i))$$

Ví dụ trên MuSiQue (định dạng chuỗi dùng trong thực nghiệm)

Phiên bản chuỗi	**Nội dung đưa vào sau ngữ cảnh X**

Gốc	`Hop 1: Who directed X? => Y`
	`Hop 2: Who is the spouse of Y? => Z`
	`Answer:`

$\mathrm{do}_{\mathrm{naive}}(z_1)$: mask riêng hop 1	`Hop 1: [MASKED] => [MASKED]` `Hop 2: Who is the spouse of Y? => Z`
$\mathrm{do}_{\mathrm{total}}(z_1)$: mask hop 1 và các hop dùng kết quả của nó	`Hop 1: [MASKED] => [MASKED]` `Hop 2: Who is the spouse of [MASKED]? => [MASKED]`
Không có chuỗi	Chỉ có X và `Answer:`

- Δ_i lớn: mô hình dựa vào z_i khi trả lời. $\Delta_i \approx 0$: mô hình bỏ qua z_i.
- Ngữ cảnh X luôn giữ nguyên, nên đáp án Z vẫn đọc được từ các đoạn văn.

Ground truth: các intervention có hiệu ứng thật biết trước

Ý tưởng. Để biết một phép đo có đúng không, cần những intervention mà hiệu ứng thật đã biết trước nhờ cách xây dựng. Phép đo đúng phải tái hiện được các hiệu ứng này.

Intervention	Ví dụ trên CLUTRR	Hiệu ứng thật
Chèn hop không liên quan	`Hop: Anna likes football.`	Bằng 0
Placebo: viết lại hop, giữ nội dung	`Ben is the son of Anna.` thay cho `Anna's son is Ben.`	Bằng 0
Mask marker: chèn token che nhưng giữ nội dung	`[MASKED] Anna's son is Ben.`	Chỉ là chi phí của token che
Thêm hop ghi sẵn đáp án	`So Clara is Anna's relative: => daughter`	Mô hình biết đáp án nếu đọc
Thêm hop ghi đáp án sai	`So Clara is Anna's relative: => mother`	Mô hình suy luận sẽ bỏ qua, mô hình chỉ đọc sẽ chép theo

- AUROC: xác suất phép đo chấm hop cần thiết cao hơn hop không liên quan. Giá trị 0.5 tương ứng ngẫu nhiên.

Dữ liệu, mô hình và giao thức thực nghiệm

Thành phần	Mô tả
CLUTRR	Composition quan hệ gia đình, chuỗi 2 đến 10 hop. Tập kiểm thử gồm câu cùng phân phối, tổ hợp quan hệ mới và chuỗi dài 5 đến 8 hop
MuSiQue	Hỏi đáp bridge 2 đến 4 hop trên Wikipedia, mỗi câu kèm 4 hoặc 8 đoạn distractor
2WikiMultihopQA	Hỏi đáp nhiều bước trên Wikipedia, dùng để kiểm tra khả năng tổng quát
Mô hình	Qwen2.5 (0.5B, 1.5B, 3B, 7B), SmolLM2-1.7B, Qwen3 (1.7B, 4B, 8B)
Tài nguyên	2 GPU T4 16 GB (Kaggle)
Giao thức	Giả thuyết và ngưỡng chấp nhận được ghi trước khi chạy (pre-registration). Khoảng tin cậy 95% bằng paired bootstrap

Các nguyên tắc bảo đảm tính chặt chẽ

Nguyên tắc	Cách thực hiện
Ground truth	Mỗi phép đo được kiểm chứng trên intervention có hiệu ứng thật biết trước (slide trước).
Pre-registration	Giả thuyết, chỉ số và ngưỡng chấp nhận được ghi trước khi chạy trên tập kiểm thử. Kết quả âm tính được báo cáo đầy đủ.
Control	Placebo, mask marker, chuỗi chỉ có hình thức, counterfactual replacement, ablation giữ nguyên đầu vào và chỉ đổi một thành phần.
So sánh cùng chi phí	Phương pháp tốn k lượt sinh được so với self-consistency k mẫu có cùng ngân sách token.
Kiểm định thống kê	Khoảng tin cậy 95% bằng paired bootstrap trên cùng tập câu hỏi.
Lặp lại	Kết luận chính được kiểm tra trên nhiều cỡ mô hình (0.5B đến 8B), hai họ mô hình và nhiều bộ dữ liệu.

Lộ trình thực nghiệm

Giai đoạn 1
Chẩn đoán
TN1 đến TN4

Kiểm chứng phép đo, đo mức mô hình dùng chuỗi, phân tích tác động của distractor.

Phát hiện: mô hình đọc đáp án có sẵn, không thực hiện composition; distractor tác động qua chuỗi.

Giai đoạn 2
Can thiệp không huấn luyện
TN5, TN6

Can thiệp ở bước decoding; chuyển composition sang rule table.

Phát hiện: can thiệp ở decoding không hiệu quả; rule table hiệu quả ở miền đóng.

Giai đoạn 3
Fine-tuning
TN7, TN8

Fine-tuning trên chuỗi, kiểm chứng trên mô hình mới và dữ liệu thật, đo lại cơ chế.

Phát hiện: fine-tuning trên chuỗi hiệu quả nhất và tổng quát hơn.

Giai đoạn 4
Ứng dụng RAG
TN9

Giảm hallucination khi trả lời từ tài liệu.

Phát hiện: mô hình học được cách abstain và bám tài liệu.

- Phát hiện của mỗi giai đoạn xác định vị trí can thiệp của giai đoạn sau.

TN1. Masking một hop không phát hiện được hop bridge

Giả thuyết. Mask riêng một hop giữa ($\mathrm{do}_{\mathrm{naive}}$, cách đo của Lanham et al., 2023) cho $\Delta \approx 0$, vì hop cuối vẫn ghi sẵn đáp án.
Thiết kế. MuSiQue, 150 câu mỗi mô hình (7B: 100 câu). So sánh $\mathrm{do}_{\mathrm{naive}}$, $\mathrm{do}_{\mathrm{total}}$ và bỏ cả chuỗi trên các hop giữa (ví dụ ở slide phương pháp đo).

Mô hình	Δ của $\mathrm{do}_{\mathrm{naive}}$	Δ của $\mathrm{do}_{\mathrm{total}}$	Chỉ mask hop cuối	Bỏ cả chuỗi	AUROC của $\mathrm{do}_{\mathrm{naive}}$
Qwen2.5-0.5B	-2.4	56.7	67.2	52.6	0.57
Qwen2.5-1.5B	0.6	56.9	69.7	55.2	0.71
SmolLM2-1.7B	-3.9	66.8	73.5	61.0	0.46
Qwen2.5-3B	0.5	49.1	55.0	50.6	0.64
Qwen2.5-7B	6.5	41.3	34.8	37.7	0.63

Δ tính bằng điểm phần trăm. AUROC phân biệt hop giữa với hop không liên quan.

Kết quả.

- $\mathrm{do}_{\mathrm{naive}}$ cho $\Delta \approx 0$ và AUROC gần ngẫu nhiên: không phát hiện được hop bridge.
- $\mathrm{do}_{\mathrm{total}}$, chỉ mask hop cuối và bỏ cả chuỗi cho kết quả xấp xỉ nhau. Trên MuSiQue, $\mathrm{do}_{\mathrm{total}}$ thực chất đo việc đáp án có nằm trong chuỗi, không đo riêng vai trò của z_1.

Kết luận. Masking một hop bị mù với hop bridge. Dù X có sẵn đáp án, mô hình lấy đáp án từ chuỗi suy luận.

TN2. Resampling với baseline cố định thổi phồng hop không liên quan

Phương pháp resampling (Bogdan et al., 2025): làm nhiễu hop z_j, cho mô hình tự sinh tiếp phần còn lại của chuỗi, rồi đo xác suất đáp án đúng. Baseline thường dùng là chuỗi chuẩn đầy đủ, với $p(Y^*) \approx 1$.
Giả thuyết. Mô hình nhỏ tự sinh tiếp thường sai, nên baseline cố định gán cả hop không liên quan là quan trọng.
Thiết kế. So sánh baseline cố định với baseline hiệu chỉnh theo vị trí $b(j)$: độ chính xác khi mô hình tự sinh tiếp từ cùng vị trí mà không bị can thiệp.

Δ trên MuSiQue	1.5B	3B
Baseline cố định, hop cần thiết	75.7	61.5
Baseline cố định, hop không liên quan	76.3	56.3
Baseline hiệu chỉnh, hop cần thiết	6.4	11.3
Baseline hiệu chỉnh, hop không liên quan	−0.3	4.3

Kết quả.

- Với baseline cố định, hop không liên quan có Δ ngang hop cần thiết. Độ lệch xấp xỉ $1 - b(j)$, với $b(j)$ từ 22% đến 44%.
- Baseline hiệu chỉnh đưa hop không liên quan về gần 0.
- Hop cần thiết sau hiệu chỉnh cũng nhỏ: mô hình tự tìm lại thông tin từ X. Resampling đo khả năng phục hồi, masking đo việc sử dụng.

Kết luận. Resampling chỉ dùng được với baseline hiệu chỉnh theo vị trí, và đo một đại lượng khác với masking.

TN3. Thiết kế: phân biệt đọc với suy luận trên CLUTRR

Giả thuyết. Mô hình nhỏ không dùng các hop quan hệ để thực hiện composition, mà chỉ đọc đáp án khi đáp án được viết sẵn trong chuỗi.
Thiết kế. 158 câu CLUTRR mỗi mô hình. Chuỗi đưa vào là chuỗi chuẩn (không do mô hình sinh), theo ba điều kiện:

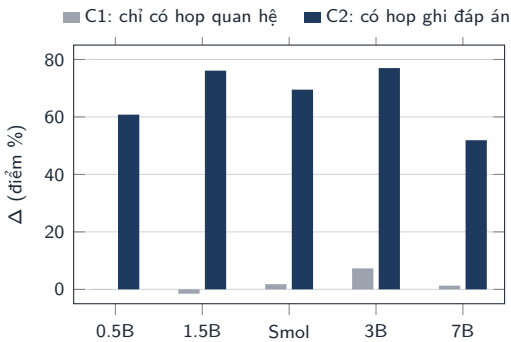
	Chuỗi đưa vào mô hình	**Nếu mô hình suy luận**	**Nếu mô hình chỉ đọc**

C1	`Hop 1: Anna's son is Ben. => Ben`
	`Hop 2: Ben's sister is Clara. => Clara`
	rồi mask một hop
		Δ lớn, vì mất một quan hệ cần cho composition	$\Delta \approx 0$

C2	C1 thêm hop cuối `So Clara is Anna's relative: => daughter`	Δ thay đổi ít	Δ lớn, vì mô hình đọc hop cuối
C3	C1 thêm hop cuối ghi đáp án sai `So Clara is Anna's relative: => mother`	Bỏ qua hop sai	Chép theo hop sai (copy)

- Ở C3, nhãn sai được chọn ngẫu nhiên trong các quan hệ khác của CLUTRR. Mỗi cặp người chỉ có đúng một nhãn đúng, nên mọi nhãn khác đều mâu thuẫn với các hop quan hệ.

TN3. Kết quả C1 và C2: chuỗi chỉ có tác dụng khi chứa sẵn đáp án



Kết quả

- C1: Δ từ −1.5 đến 7.3 điểm. Mask một hop quan hệ gần như không ảnh hưởng.
- C2: cùng các hop đó nhưng thêm một dòng ghi đáp án, Δ tăng lên 52 đến 77 điểm.
- Ở 3B, 7.3 [3.8, 11.0] điểm có ý nghĩa thống kê nhưng nhỏ hơn hiệu ứng ở C2 khoảng mười lần.
- Khi được đưa chuỗi chuẩn đầy đủ, mô hình chỉ trả lời đúng 15% (0.5B) đến 33% (7B).

Kết luận. Các hop quan hệ gần như không tham gia vào câu trả lời. Chuỗi chỉ có tác dụng khi đáp án được viết sẵn trong chuỗi.

TN3. Kết quả C3 (copy test): mô hình chép theo đáp án sai

Lý do cần copy test. C1 có thể bằng 0 vì mô hình không biết làm composition, không phải vì nó chỉ đọc. Copy test tách hai khả năng này: đo tỷ lệ chép đáp án sai riêng trên những câu mô hình đã trả lời đúng khi chưa có hop sai.

Mô hình	Chép theo, mọi câu	Chép theo, câu tự giải đúng	Số câu tự giải đúng
Qwen2.5-0.5B	66.5% [58.9, 74.1]	70.8% [54.2, 87.5]	24
Qwen2.5-1.5B	58.2% [50.6, 66.5]	63.0% [44.4, 81.5]	27
SmolLM2-1.7B	56.3% [48.1, 64.6]	57.1% [42.9, 71.4]	42
Qwen2.5-3B	46.2% [38.0, 54.4]	47.7% [34.1, 61.4]	44
Qwen2.5-7B	22.9% [16.1, 30.5]	10.3% [2.6, 20.5]	39

Khoảng tin cậy 95% bằng bootstrap. Mỗi mô hình 158 câu (7B: 118 câu).

Kết quả.

- Đến 3B, tỷ lệ chép trên câu tự giải đúng ngang với mọi câu: hop ghi sẵn đáp án lấn át kết quả mô hình tự tính được.
- Ở 7B, đáp án sai bị bác bỏ khi mô hình tự giải được (10.3%), nhưng ở C1 các hop quan hệ vẫn không mang hiệu ứng (1.3 điểm). 7B thực hiện composition, nhưng không thông qua chuỗi.

Kết luận. Kết quả C1 không do mô hình thiếu năng lực composition. Với mô hình đến 3B, hop ghi sẵn đáp án được ưu tiên hơn kết quả tự tính.

TN3. Có đủ thông tin nhưng không làm composition

(a) Chuỗi tự sinh đi đúng đường vẫn không giúp

Tách các câu mà chuỗi CoT do mô hình tự sinh nhắc đủ mọi nhân vật trên đường quan hệ đúng.

CoT	Chuỗi đi đủ đường	Chuỗi khác
Qwen2.5-1.5B	17.1% (n=41)	18.3% (n=197)
SmolLM2-1.7B	15.2% (n=33)	22.4% (n=205)

(b) Mô hình trích xuất đúng quan hệ

Khi được yêu cầu liệt kê các quan hệ trong câu chuyện, mô hình tìm được 70% (1.5B), 71% (3B) và 87% (7B) số quan hệ trên đường đúng.

(c) Cùng thông tin, đổi bên thực hiện composition

Giữ nguyên danh sách quan hệ đã trích xuất, chỉ thay bên ghép quan hệ: chính mô hình hoặc rule table. Chuỗi 2 đến 4 hop.

	Mô hình ghép	Rule table ghép
Qwen2.5-1.5B	32.9%	46.2%
Qwen2.5-3B	28.5%	54.4%
Qwen2.5-7B	36.1%	71.5%

Chênh lệch $+13.3$, $+25.9$ và $+35.4$ điểm, đều có khoảng tin cậy lớn hơn 0.

Kết luận. Thông tin cần thiết có mặt và được mô hình đọc đúng. Điểm hỏng là bước composition.

Control: loại trừ các giải thích khác cho kết quả masking

Mục đích. Kiểm tra rằng hiệu ứng đo được đến từ nội dung bị xóa, không đến từ token `[MASKED]`, từ cách viết hay từ hình thức của chuỗi.

- **Hình thức và nội dung:** chuỗi cùng hình dạng nhưng mọi hop bị mask, so với không có chuỗi (hình thức) và so với chuỗi đầy đủ (nội dung).
- **Placebo:** viết lại hop, giữ nguyên nội dung. **Mask marker:** chèn `[MASKED]` vào cùng các hop như $\mathrm{do}_{\mathrm{total}}$ nhưng giữ nội dung.
- **Counterfactual replacement:** thay thực thể bằng một tên khác thay vì mask, không dùng token che.

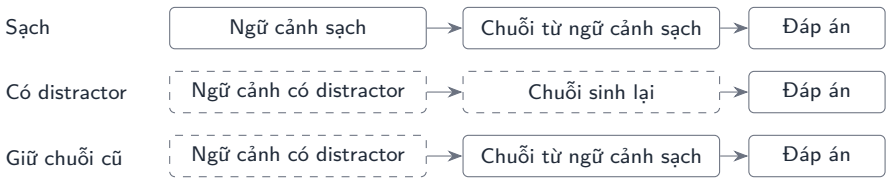
MuSiQue (điểm)	Hình thức	Nội dung	Placebo	Mask marker	Counterfactual	$\mathrm{do}_{\mathrm{total}}$
Qwen2.5-0.5B	4.1	48.5	−3.1	7.3	64.2	56.7
Qwen2.5-1.5B	3.3	51.9	0.2	0.0	66.5	56.9
SmolLM2-1.7B	−5.4	66.4	1.1	2.3	71.6	66.8
Qwen2.5-3B	2.3	48.3	0.3	−0.3	61.2	49.1
Qwen2.5-7B	2.2	35.4	0.9	5.7	45.9	41.3

Placebo, mask marker, counterfactual và $\mathrm{do}_{\mathrm{total}}$ tính trên các hop giữa. CLUTRR có hop ghi đáp án cho cùng kết luận: hình thức từ −2.2 đến 0.4, nội dung từ 45.5 đến 75.6.

Kết luận. Hiệu ứng đến từ nội dung của chuỗi. Hình thức, placebo và token che đều cho hiệu ứng nhỏ; thay thực thể không dùng token che cho cùng kết luận với masking.

TN4. Distractor gây hại thông qua chuỗi suy luận (mediation analysis)

Giả thuyết. Đoạn distractor làm giảm độ chính xác chủ yếu vì làm hỏng chuỗi suy luận, không phải vì tác động trực tiếp lên bước trả lời.
Thiết kế. MuSiQue, Qwen2.5-3B, 500 câu, thêm 4 đoạn distractor. Ba trạng thái được so sánh:



Chế độ trả lời	NDE	TIE
CoT	−0.6	−5.0
Trả lời trực tiếp	−3.8	−2.0

- NDE (natural direct effect): thay đổi khi giữ chuỗi cũ, chỉ đổi ngữ cảnh.
- TIE (total indirect effect): thay đổi do chuỗi bị sinh lại khác đi.

Kết luận. Với CoT, tác hại của distractor đi qua chuỗi (TIE −5.0 điểm, NDE gần 0). Sửa ở bước đọc đáp án sau khi chuỗi đã viết xong không xử lý được nguyên nhân.

TN5. Can thiệp ở bước decoding không cải thiện kết quả

Giả thuyết. Từ TN3 và TN4, can thiệp lúc decoding không sửa được lỗi suy luận. Hai phương pháp được kiểm chứng:

- HGCD (đề xuất của luận văn): sau khi chuỗi được sinh, cộng thêm vào điểm của mỗi đáp án ứng viên mức phụ thuộc nhân quả của nó vào các hop.
- Lọc ngữ cảnh bằng attention: trước khi sinh chuỗi, chỉ giữ 4 đoạn có trọng số attention từ câu hỏi cao nhất.

HGCD, độ chính xác (%)

	CoT	HGCD
CLUTRR, Qwen2.5-1.5B	18.1	18.1
CLUTRR, SmolLM2-1.7B	21.4	21.0
MuSiQue, Qwen2.5-1.5B	20.8	22.5
MuSiQue, SmolLM2-1.7B	15.0	15.8

Lọc ngữ cảnh, MuSiQue, Qwen2.5-3B (EM %)

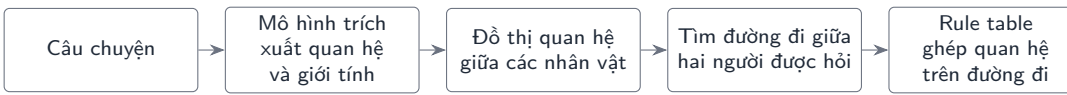
	4 distractor	8 distractor
CoT	38.8	31.6
Self-consistency 5 mẫu	41.4	35.6
Lọc theo attention	33.8	27.4
Chỉ giữ đoạn chuẩn	48.6	45.6

- HGCD không khác CoT ($|\Delta| \leq 1.7$ điểm, $p \geq 0.6$), đúng như TN3 dự đoán: không có phụ thuộc để khuếch đại.
- Lọc theo attention loại nhầm đoạn bridge thứ hai, vì đoạn này chỉ liên quan tới thực thể trung gian chưa xuất hiện trong câu hỏi.

Kết luận. Can thiệp ở bước decoding không hiệu quả. Cần tác động trực tiếp vào điểm nghẽn mà TN3 chỉ ra là composition.

TN6. Chuyển composition sang rule table

Giả thuyết. Mô hình trích xuất quan hệ tốt nhưng làm composition kém (TN3), nên tách hai việc: mô hình trích xuất, rule table thực hiện composition.



Ví dụ. Mô hình trích ra `Anna's son is Ben`, `Ben's sister is Clara`. Đường đi Anna $\rightarrow$ Ben $\rightarrow$ Clara.

Rule table: son $\circ$ sister $=$ daughter.

- Rule table gồm 126 quy tắc dạng $r_1 \circ r_2 = r_3$, quy nạp tự động từ nhãn của tập huấn luyện (đúng 95% trên chuỗi chuẩn).
- Mô hình trích xuất 5 lần và bỏ phiếu. Đối thủ là self-consistency 10 mẫu, có chi phí sinh token không nhỏ hơn.
- Ablation ở TN3 (c) dùng cùng pipeline: giữ nguyên quan hệ đã trích xuất, chỉ thay bên ghép.

TN6. Kết quả: rule table tăng mạnh độ chính xác



V: cùng phân phối, 2 đến 4 hop. S: tổ hợp quan hệ mới. L: chuỗi dài 5 đến 8 hop.

Kết quả

- Hơn self-consistency 10 mẫu từ 21 đến 37 điểm trên chuỗi 2 đến 4 hop.
- Chuỗi dài: hơn 24 điểm ở 7B, không khác biệt ở 1.5B.
- Mô hình 1.5B dùng rule table (60.7%) vượt mô hình 7B dùng self-consistency (43.3%).

Kết luận. Rule table hiệu quả, và theo ablation ở TN3 (c) phần tăng đến từ composition chứ không từ bước trích xuất. Cách này chỉ áp dụng được ở miền có tập quan hệ đóng.

TN7. Fine-tuning trên chuỗi suy luận: thiết kế

Giả thuyết. Mô hình không làm được composition do cách prompting chứ không do giới hạn năng lực. Fine-tuning trên chuỗi sẽ dạy được mô hình tự làm composition, cả trên chuỗi dài hơn dữ liệu huấn luyện.

Thiết kế.

- LoRA (rank 16) trên 3000 câu CLUTRR, chỉ gồm chuỗi 2 đến 4 hop. Chuỗi huấn luyện được dựng tự động từ đường quan hệ có sẵn trong dữ liệu.
- Kiểm tra trên câu cùng phân phối, tổ hợp quan hệ mới và chuỗi dài 5 đến 8 hop chưa từng thấy khi huấn luyện.

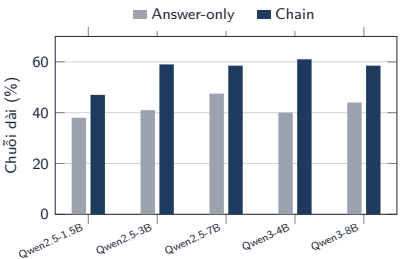
Dạng dữ liệu	**Đầu ra mục tiêu cho cùng một câu chuyện**
Answer-only	`Answer: Clara is Anna's daughter.`

Chain	`Hop 1: Anna's son is Ben. => Ben`
	`Hop 2: Ben's sister is Clara. => Clara`
	`Answer: Clara is Anna's daughter.`

- Hai dạng dùng cùng câu chuyện và cùng số bước huấn luyện, chỉ khác có hay không có các hop.

TN7. Kết quả: fine-tuning trên chuỗi hiệu quả nhất

Qwen2.5-3B, độ chính xác (%)	Cùng phân phối	Tổ hợp mới	Chuỗi dài
CoT, không fine-tune	36.3	30.4	26.0
Rule table (TN6)	70.0	59.5	38.5
Fine-tune answer-only	90.3	55.1	41.0
Fine-tune chain	**94.7**	**77.8**	**59.0**



Kết quả

- Fine-tune chain đưa 3B từ 36.3% lên 94.7%, vượt rule table trên chuỗi dài.
- Chain hơn answer-only từ 9 đến 21 điểm trên chuỗi dài, lặp lại ở năm mô hình thuộc hai họ.
- Trên câu cùng phân phối, answer-only gần ngang chain: khác biệt nằm ở khả năng tổng quát.

Kết luận. Mô hình làm được composition sau fine-tuning trên chuỗi, kể cả trên chuỗi dài hơn dữ liệu huấn luyện.

TN7. Kiểm chứng trên mô hình mới và trên dữ liệu thật

Qwen3 với chế độ thinking (CLUTRR, %)

	Tổ hợp mới	Chuỗi dài
Qwen3-4B, few-shot	38.0	27.5
Qwen3-4B, thinking	59.0	22.0
Qwen3-4B, fine-tune chain	77.8	61.0
Qwen3-8B, few-shot	37.3	27.5
Qwen3-8B, thinking	60.0	31.7
Qwen3-8B, fine-tune chain	83.5	58.5

Thinking đo trên 100 câu (4B) và 60 câu (8B), giới hạn 1500 token; lượt chưa xong tính là sai.

2WikiMultihopQA (Wikipedia, Qwen2.5-3B, EM %)

Cấu hình	EM
Few-shot	28.8
Fine-tune answer-only	50.0
Fine-tune chain	56.0
Huấn luyện trên câu compositional, kiểm tra trên câu inference:	
Fine-tune answer-only	22.6
Fine-tune chain	40.6

Kết luận. Chế độ thinking của mô hình mới chưa thay thế được fine-tuning trên chuỗi. Trên dữ liệu thật, chuỗi giúp tổng quát sang loại câu hỏi chưa thấy khi huấn luyện (+18 điểm).

TN8. Sau fine-tuning, câu trả lời phụ thuộc vào chuỗi

Thiết kế. Đo lại TN3 trên mô hình đã fine-tune (120 câu CLUTRR). Trên CLUTRR đáp án không nằm trong chuỗi, nên masking không xóa đáp án như ở TN1.

	Δ khi mask hop giữa (điểm)		Chép hop ghi đáp án sai	
Mô hình	**Trước**	**Sau**	**Trước**	**Sau**
Qwen2.5-1.5B	-1.5	36 đến 42	63.0%	13 đến 22%
Qwen2.5-3B	7.3	41 đến 44	47.7%	26 đến 32%
Qwen2.5-7B	1.3	39	10.3%	47.5%

Khoảng giá trị là kết quả của hai seed. Trên chuỗi tuyến tính, $\mathrm{do}_{\mathrm{total}}$ cắt mọi liên kết phía sau, nên đo việc dùng chuỗi chứ không cô lập riêng một hop.

Kết quả

- Δ tăng từ mức nhiễu lên khoảng 40 điểm: sau fine-tuning, câu trả lời phụ thuộc vào chuỗi.
- Mô hình vẫn tin hop ghi đáp án ở cuối. Với 7B, tỷ lệ chép đáp án sai tăng sau fine-tuning.
- DPO với cặp counterfactual giảm tỷ lệ chép xuống 4.5% đến 7.2% nhưng làm giảm 5 đến 13 điểm trên chuỗi dài. GRPO không cải thiện chuỗi dài.

Kết luận. Fine-tuning thay đổi cơ chế: mô hình chuyển sang dựa vào chuỗi. DPO và GRPO chỉ cho đánh đổi, không cho cải thiện thêm.

TN9. Giảm hallucination khi trả lời từ tài liệu: thiết kế

Giả thuyết. Thêm vào dữ liệu fine-tuning các tài liệu thiếu bằng chứng và tài liệu mâu thuẫn sẽ dạy mô hình abstain khi tài liệu không đủ và bám theo tài liệu khi tài liệu khác với kiến thức đã nhớ.

Điều kiện	**Intervention lên tài liệu (MuSiQue)**	**Hành vi đúng**
Answerable	Giữ nguyên: đoạn bằng chứng và 4 đoạn distractor	Trả lời đúng
Unanswerable	Bỏ một đoạn bằng chứng; đáp án không còn xuất hiện trong tài liệu	`Answer: unanswerable`
Conflict	Thay đáp án ở mọi chỗ trong tài liệu bằng một thực thể cùng loại	Trả lời theo tài liệu

Ví dụ conflict. Tài liệu ghi vợ của Y là W thay cho Z. Mô hình bám tài liệu phải trả lời W; trả lời Z nghĩa là dùng kiến thức đã nhớ.

- Ba cách fine-tuning: chain thông thường; thêm 30% mẫu unanswerable; thêm cả mẫu unanswerable và conflict.
- Qwen2.5-3B (2 seed) và Qwen3-4B, 300 câu mỗi điều kiện. Ngưỡng chấp nhận đặt trước: độ chính xác trên câu answerable không giảm quá 5 điểm.

TN9. Kết quả: mô hình học được cách abstain và bám tài liệu

Fine-tuning	Qwen2.5-3B (seed 0)				Qwen3-4B			
	Đúng	Abstain nhầm	Abstain đúng	Theo tài liệu	Đúng	Abstain nhầm	Abstain đúng	Theo tài liệu
Không fine-tune, có chỉ dẫn abstain	29.3	17.7	35.7	11.7	31.7	35.7	73.3	13.3
Chain thông thường	52.0	0.0	0.0	22.3	60.7	0.0	0.0	30.3
+ unanswerable	44.3	19.3	61.7	21.0	56.7	12.3	70.7	32.0
+ unanswerable + conflict	46.7	11.7	55.7	42.7	57.3	10.7	70.7	52.7

Đúng và abstain nhầm: trên câu answerable. Abstain đúng: trên câu unanswerable. Theo tài liệu: trên câu conflict. Đơn vị %. Seed 1 của Qwen2.5-3B cho kết quả cùng chiều.

Đạt

- Abstain khi thiếu bằng chứng tăng từ 0% lên 56% đến 71%, lặp lại ở cả 3 lần chạy.
- Trả lời theo tài liệu khi conflict tăng 21 đến 24 điểm, lặp lại ở cả 3 lần chạy.

Chưa đạt

- Độ chính xác trên câu answerable giảm 4 đến 8 điểm, vượt ngưỡng 5 điểm đặt trước.
- DPO và GRPO chỉ dời điểm cân bằng giữa trả lời và abstain, không cải thiện thật.

Kết luận. Hai loại dữ liệu đơn giản dạy được mô hình abstain và bám tài liệu. Nguồn lỗi còn lại chủ yếu là độ chính xác gốc (44% đến 61%) trên câu answerable.

Tổng hợp kết quả

TN	Giả thuyết	Kết quả chính	Đánh giá
TN1	Masking một hop không thấy hop bridge	$\Delta \approx 0$, AUROC 0.46 đến 0.71	Chấp nhận
TN2	Resampling với baseline cố định thổi phồng hop không liên quan	56 đến 76 điểm, về ≤ 4 sau hiệu chỉnh	Chấp nhận
TN3	Mô hình nhỏ đọc chứ không suy luận	C1 gần 0; C2 từ 52 đến 77 điểm; chép đáp án sai 48% đến 71% (đến 3B); control đều nhỏ	Chấp nhận
TN4	Distractor gây hại qua chuỗi	NDE -0.6, TIE -5.0	Chấp nhận
TN5	Can thiệp ở decoding cải thiện kết quả	Không khác CoT	Bác bỏ
TN6	Rule table cải thiện kết quả	Hơn self-consistency 21 đến 37 điểm	Chấp nhận
TN7	Fine-tuning trên chuỗi dạy được composition	3B: 36.3% lên 94.7%; chain hơn answer-only 9 đến 21 điểm	Chấp nhận
TN8	Sau fine-tuning mô hình dựa vào chuỗi	Δ khoảng 40 điểm	Chấp nhận
TN9	Dữ liệu unanswerable và conflict giảm hallucination	Abstain 56% đến 71%; theo tài liệu tăng 21 đến 24 điểm; độ chính xác giảm 4 đến 8 điểm	Chấp nhận một phần

Hạn chế

- Dữ liệu chủ yếu là CLUTRR (tổng hợp) và MuSiQue. Rule table ở TN6 chỉ dùng được ở miền có tập quan hệ đóng.
- Mô hình từ 0.5B đến 8B. Chưa kiểm chứng trên mô hình rất lớn như GPT-5 hay Claude Opus.
- Nhiều kết quả chỉ có một seed, và số câu tự giải đúng trong copy test nhỏ (24 đến 44 câu). Các kết luận chính đã được lặp lại trên nhiều mô hình.
- Trên MuSiQue, $\mathrm{do}_{\mathrm{total}}$ đo việc đáp án có trong chuỗi, không đo riêng vai trò từng hop. Kết luận về suy luận dựa trên CLUTRR.
- Nhãn unanswerable ở TN9 được dựng bằng cách bỏ đoạn văn, mô hình vẫn có thể trả lời từ kiến thức đã nhớ.

Kết luận và hướng phát triển

Kết luận

1. Masking một hop và resampling với baseline cố định cho kết quả lệch. Cần control và baseline hiệu chỉnh.
2. Mô hình nhỏ chưa fine-tune đọc đáp án có sẵn trong chuỗi nhưng không dùng chuỗi để làm composition, dù có đủ thông tin.
3. Can thiệp ở bước decoding không hiệu quả. Rule table hiệu quả ở miền đóng. Fine-tuning trên chuỗi hiệu quả và tổng quát hơn.
4. Dữ liệu unanswerable và conflict giúp mô hình abstain và bám tài liệu khi trả lời từ tài liệu.

Hướng phát triển

- Nâng độ chính xác gốc khi trả lời từ tài liệu bằng dữ liệu chuỗi lớn và đa dạng hơn.
- Kiểm chứng với hệ thống RAG dùng retriever thật.
- Áp dụng copy test và các intervention có ground truth cho mô hình lớn qua API.

Xin trân trọng cảm ơn

Kính mong nhận được ý kiến đóng góp của thầy cô

Phụ lục. Tài liệu tham khảo chính

1. Lanham et al. Measuring Faithfulness in Chain-of-Thought Reasoning. arXiv:2307.13702, 2023.
2. Dziri et al. Faith and Fate: Limits of Transformers on Compositionality. NeurIPS 2023.
3. Paul, West, Bosselut, Faltings. Making Reasoning Matter: Measuring and Improving Faithfulness of Chain-of-Thought Reasoning. Findings of EMNLP 2024.
4. Bogdan, Macar, Nanda, Conmy. Thought Anchors: Which LLM Reasoning Steps Matter. arXiv:2506.19143, 2025.
5. Somov, Chaichuk, Seleznyov, Panchenko, Tutubalina. Breaking the Chain: A Causal Analysis of LLM Faithfulness to Intermediate Structures. arXiv:2603.16475, 2026.

Phụ lục. Mã nguồn và kết quả

Nội dung	Đường dẫn
Giả thuyết đăng ký trước và kết luận từng vòng	`REVIEW.md`
TN1 đến TN3, control	`results/reliance_v2/`, `tools/check_r1_triviality.py`
TN4	`results/mediation_n500/`
TN5, TN6	`results/decoding/`, `results/causaldec/`
TN7, TN8	`results/cftrain/`, `results/cfrl/`, `results/egen/`
TN9	`hgcd/hall.py`, `results/hall/`