Read, Not Reasoned?

Can thiệp nhân quả có ground truth lên chuỗi suy luận nhiều bước của mô hình ngôn ngữ nhỏ

Người thực hiện: [Họ tên học viên]
GVHD: [Tên giáo sư hướng dẫn]

2026

Nội dung trình bày

1. Vấn đề và câu hỏi nghiên cứu
2. Cách tiếp cận: tạo ground truth để đo
3. Bức tranh tổng thể: cái gì đúng, cái gì không
4. Chẩn đoán: mô hình *đọc* chứ không *suy luận* (R1–R5)
5. Decoding: hướng nào không giúp, hướng nào giúp (D1–D3)
6. Vòng thí nghiệm đang chạy và kế hoạch kiểm tra tính tổng quát
7. Hạn chế, những chỗ đã tự sửa
8. Kết luận và hướng tiếp theo

Phụ lục: thuật ngữ · số liệu và vị trí file trong repo

Vấn đề: viết ra một bước có nghĩa là đã dùng bước đó?

Chain-of-thought (CoT) yêu cầu mô hình viết các bước trung gian trước khi trả lời. Nhưng **viết** một bước chưa chắc là **dùng** bước đó.

- Nhiều nghiên cứu xoá hoặc sửa một bước rồi xem đáp án có đổi không. Điểm yếu chung: **không ai biết bước nào thật sự cần thiết**, nên không kiểm chứng được phương pháp đo nào đúng.
- Với mô hình nhỏ (0.5B–7B), câu hỏi thực dụng hơn: **có cách nào làm chúng trả lời đúng hơn** khi câu hỏi cần nhiều bước (hỏi đáp trên nhiều tài liệu, quan hệ họ hàng, truy vấn có quan hệ)?
- Hướng ban đầu của đề tài: chỉnh *decoding* (cách chọn token) để khuếch đại phần đáp án "do chuỗi gây ra".

Hai câu hỏi trung tâm

1. Đáp án có *phụ thuộc nhân quả* vào chuỗi suy luận không, và đi qua đường nào?
2. Từ câu trả lời đó, can thiệp ở đâu thì mô hình trả lời đúng hơn: ở bước *đọc đáp án*, hay ở bước *tạo chuỗi*?

Hai loại câu hỏi nhiều bước dùng để tách "đọc" khỏi "suy luận"

Bridge (MuSiQue, Wikipedia)

Hỏi: Vợ của đạo diễn phim X là ai?

`Hop 1: Đạo diễn phim X là ... ⇒ Y`
`Hop 2: Vợ của Y là ... ⇒ Z`

Mỗi bước tìm một thực thể, bước sau dùng nó. Đáp án Z **được viết ra** ở bước cuối: chỉ cần đọc bước cuối là trả lời được.

Compositional (CLUTRR, quan hệ gia đình)

Chuyện: Anna đưa con trai Ben đi chơi; Ben và chị gái Clara nướng bánh. **Hỏi:** Clara là gì của Anna?

`Hop 1: Ben là con trai của Anna.`
`Hop 2: Clara là chị gái của Ben.`

Đáp án "**con gái**" **không xuất hiện** trong chuỗi: phải tự *tính* son ∘ sister = daughter.

Ý tưởng then chốt

Nếu mô hình thật sự suy luận, chuỗi phải có tác dụng ở *cả hai* loại. Nếu nó chỉ có tác dụng khi đáp án được viết sẵn (bridge) thì mô hình đang **đọc** chứ không **suy luận**.

Cách tiếp cận: tự tạo ground truth bằng can thiệp có đáp án biết trước

1. Chuỗi gold

Viết sẵn chuỗi đúng từ đường đi gold của dữ liệu (MuSiQue có phân rã, CLUTRR có đồ thị quan hệ).

2. Bước thừa

Chèn một bước *đúng sự thật nhưng không liên quan*. Mức cần thiết thật của nó **bằng 0**; một phép đo tốt phải chấm nó ≈ 0.

3. Can thiệp hiệu ứng 0

Đổi tên người, đổi thứ tự câu, thêm distractor, câu trung tính (placebo). Về logic, đáp án đúng không đổi.

4. Mediation chính xác

Tự *đặt* chuỗi vào mô hình, nhờ đó quan sát trực tiếp hiệu ứng trực tiếp và hiệu ứng qua chuỗi trên từng câu.

Hai kiểu che một bước *j*:

- $\mathrm{do}_{\mathrm{naive}}$: che đúng bước *j*.
- $\mathrm{do}_{\mathrm{total}}$: che bước *j* *và* mọi chỗ các bước sau nhắc lại kết quả của nó.

Các control kèm theo: placebo (viết lại cùng nghĩa), mask-marker (chèn `[MASKED]` nhưng giữ nội dung), marker-tree (cùng số token mask trên cả nhánh).

Dữ liệu, mô hình và giao thức thống kê

Mục	Chi tiết
CLUTRR	chuỗi quan hệ gia đình sạch, 11.708 train / 635 test; thêm một task *chưa từng dùng* để kiểm chứng
MuSiQue-Ans	câu hỏi Wikipedia thật, có phân rã gold; ngữ cảnh gồm đoạn đúng và 4 (hoặc 8) distractor
Mô hình	Qwen2.5-0.5B/1.5B/3B/7B-Instruct, SmolLM2-1.7B; greedy, fp16
Phần cứng	Kaggle T4 16GB; không fine-tune ở phần chẩn đoán
Thống kê	bootstrap 95% CI, so sánh cặp, McNemar

Kỷ luật thí nghiệm

- **Đăng ký trước**: giả thuyết, ngưỡng go/no-go ghi vào `REVIEW.md` *trước* khi chạy GPU.
- Ngưỡng thành công: vượt baseline tốt nhất (CoT hoặc self-consistency *cùng compute*) ≥ 2 điểm, CI > 0.
- Phát hiện post hoc chỉ được chấp nhận sau khi xác nhận lại trên dữ liệu chưa dùng.
- Mọi bảng sinh từ code, không gõ tay.

Tổng quan: cái gì đúng, cái gì không

Mã	Phát hiện	Con số chính	Kết luận
R1	Che một bước đơn lẻ bỏ sót suy luận kiểu bridge; che kèm các bước phụ thuộc thì đúng	$\mathrm{do}_{\mathrm{naive}}$: -4 đến $+6.5$ điểm; $\mathrm{do}_{\mathrm{total}}$: 41–67 điểm	THÀNH CÔNG
R2	Resampling baseline cố định chấm bước thừa thành "cần thiết"	bước thừa 56–78 điểm; sửa còn ≤ 4	THÀNH CÔNG
R3	**Chuỗi được đọc, không được suy luận**	CLUTRR: -1.5 đến $+7.3$; có đáp án viết sẵn: 52–77	THÀNH CÔNG
R4	Distractor hại CoT *qua* chuỗi	NDE ≈ 0; TIE $-3.6/-5.0$	THÀNH CÔNG
R5	Chỉnh bước đọc đáp án (HGCD) không giúp	$\lvert\Delta\rvert \leq 1.7$, $p \geq 0.6$	KHÔNG HIỆU QUẢ
D1	Lọc distractor bằng attention trước khi sinh (MuSiQue)	không vượt SC; top-4 còn tệ hơn CoT	KHÔNG HIỆU QUẢ
D2	Trích fact rồi để bảng luật hợp thành (CLUTRR)	hơn SC cùng compute $+21$ đến $+37$	THÀNH CÔNG
D3	Ablation: cùng fact, đổi bên hợp thành	luật hơn LLM $+13$ đến $+35$	THÀNH CÔNG

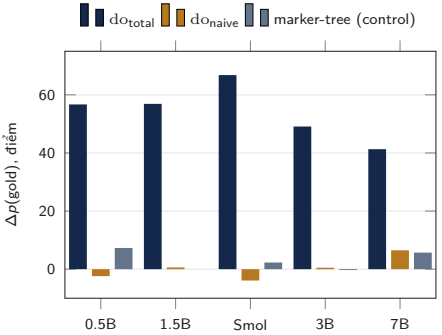
R1–R4 là kết quả chẩn đoán (đo lường); R5, D1–D3 là kết quả can thiệp (làm cho mô hình trả lời đúng hơn). "Thành công" ở R1–R4 nghĩa là giả thuyết đã dự đoán được xác nhận.

R1 · Che một bước đơn lẻ không thấy được bước cần thiết

Vì sao? Bước sau đã chép lại kết quả của bước trước. Che Hop 1 nhưng Hop 2 vẫn ghi "Y" thì mô hình không mất thông tin: $\mathrm{do}_{\mathrm{naive}}$ luôn báo "không cần thiết", *kể cả khi Hop 1 cần thiết*. Đây là một đồng nhất thức (controlled direct effect), không phải nhiễu.

Kiểm tra: che một bước gold không phải bước cuối (MuSiQue); đo thay đổi xác suất đáp án đúng.

AUC (0.5 = đoán mò)	$\mathrm{do}_{\mathrm{total}}$	$\mathrm{do}_{\mathrm{naive}}$
Qwen-1.5B	0.98	0.82
Qwen-3B	0.97	0.76
Qwen-7B	0.86	0.71



Kết luận

Muốn đo một bước có cần thiết không phải can thiệp cả các bước phụ thuộc vào nó; phương pháp "xoá một bước" đánh giá thấp có hệ thống các bước trung gian. Placebo ở mức đoán mò (AUC ≈ 0.5); marker-tree chỉ 0–7 điểm nên hiệu ứng lớn không phải do che nhiều chữ.

R2 · Resampling với baseline cố định bị lệch đúng bằng $1 - r$

Phương pháp phổ biến: làm hỏng một bước, cho mô hình tự viết tiếp, xem tỷ lệ đúng giảm bao nhiêu.

Vấn đề: so với chuỗi gold gốc (luôn đúng), nhưng mô hình tự viết tiếp chỉ đúng với tỷ lệ $r < 1$. Phần sai do mô hình *viết tiếp kém* $(1 - r)$ bị tính nhầm là "do bước bị hỏng".

Ví dụ

Nếu $r = 0.3$ thì *mọi* bước, kể cả bước hoàn toàn không liên quan, bị chấm "cần thiết" khoảng 70 điểm. Cách sửa: so với một baseline *cũng được resample*.

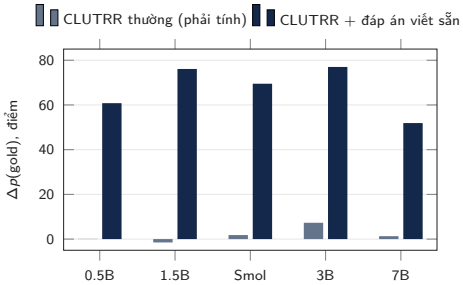
MuSiQue (điểm "cần thiết")	**1.5B**	**3B**
Cố định: bước cần thiết	75.7	61.5
Cố định: **bước thừa**	**76.3**	**56.3**
Resample: bước cần thiết	6.4	11.3
Resample: bước thừa	−0.3	4.3
AUC, cố định	0.52	0.55
AUC, resample	0.67	0.64

Mô hình chỉ tự viết tiếp đúng 22–44% số lần, nên 56–78 chính là $1 - r$.

Kết luận

Một số số đo "step necessity" đã công bố chủ yếu phản ánh việc mô hình viết tiếp kém, không phản ánh tầm quan trọng của bước. Resampling đo *khôi phục được không*, còn $\mathrm{do}_{\mathrm{total}}$ đo *bước viết ra có được dùng không*.

R3 · Kết quả chính: chuỗi được *đọc*, không được *suy luận*



Che một bước quan hệ: chỉ có tác dụng khi đáp án được *viết sẵn*.

Phép thử $T_{\text{copy-wrong}}$: thêm một bước cuối viết đáp án *sai*, mâu thuẫn với các bước quan hệ. Mô hình có chép theo không?

	Chép sai	**Khi tự giải đúng**
Qwen-0.5B	66.5%	70.8%
Qwen-1.5B	58.2%	63.0%
Qwen-3B	46.2%	47.7%
Qwen-7B	22.9%	**10.3%**

Kết luận

Đến 3B, mô hình chép đáp án sai *như nhau* dù nó tự giải được câu đó (cột 2 ≈ cột 3): chữ viết sẵn *đè lên* lời giải của chính nó. Ở 7B mới có bước chuyển (chỉ 10%), nhưng các bước quan hệ vẫn không có hiệu ứng đo được.

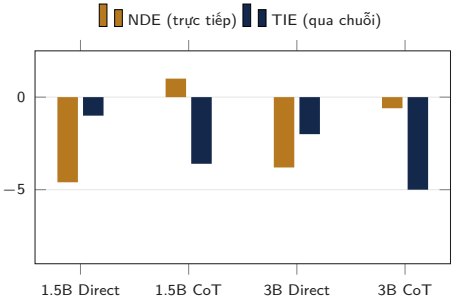
R4 · Distractor làm hại CoT thông qua chuỗi, không phải trực tiếp

Với mỗi câu hỏi chạy ba lần:

1. input gốc, chuỗi gốc;
2. input có thêm distractor, chuỗi *sinh lại*;
3. input có distractor, nhưng **ép dùng lại chuỗi gốc**.

TE = (2)−(1); NDE = (3)−(1) (trực tiếp); TIE = TE − NDE (qua chuỗi). Vì tự đặt chuỗi nên các đại lượng được *quan sát*, không cần giả định.

MuSiQue, 8 distractor, $n = 500$, EM (điểm).



Kết luận

Với CoT, giữ chuỗi cũ thì distractor gần như vô hại (NDE ≈ 0); toàn bộ tác hại đến từ việc mô hình viết ra *chuỗi khác*. Với Direct và CAD thì ngược lại. Vì vậy các phương pháp tương phản ở bước đọc đáp án (CAD) *nhắm sai chỗ* đối với CoT. Độ lớn thật chỉ 3–6 điểm; pilot 120 câu từng báo ≈ 10 điểm và đã được sửa.

R5 · Decoding ở bước đọc đáp án (HGCD) không giúp

HGCD là phương pháp của đề xuất ban đầu: cộng vào xác suất mỗi đáp án một lượng $\alpha\times$ (hiệu ứng nhân quả trung bình của các bước liên quan, tính bằng $\mathrm{do}_{\mathrm{total}}$) để khuếch đại phần "do chuỗi gây ra".

Accuracy (%)	CoT	HGCD	Calibration
CLUTRR, Qwen-1.5B	18.1	18.1	23.9
CLUTRR, SmolLM2	21.4	21.0	24.8
MuSiQue, Qwen-1.5B	20.8	22.5	–
MuSiQue, SmolLM2	15.0	15.8	–

Vì sao thất bại: R3 đã dự đoán

HGCD chỉ khuếch đại một sự phụ thuộc *có thật* và tác động *sau khi* chuỗi đã sinh. Nhưng đáp án không phụ thuộc vào nội dung suy luận của chuỗi (R3) và tác hại của distractor không nằm ở bước đọc (R4).

- HGCD = CoT ($|\Delta| \leq 1.7$, mọi $p \geq 0.6$).
- Calibration có tăng, nhưng không dùng thông tin từ chuỗi và mong manh (đổi input trung tính làm SmolLM2 giảm 5 điểm); sau kiểm tra nó $\approx$ sinh đáp án tự do.

D1 · MuSiQue: lọc distractor trước khi sinh chuỗi không giúp

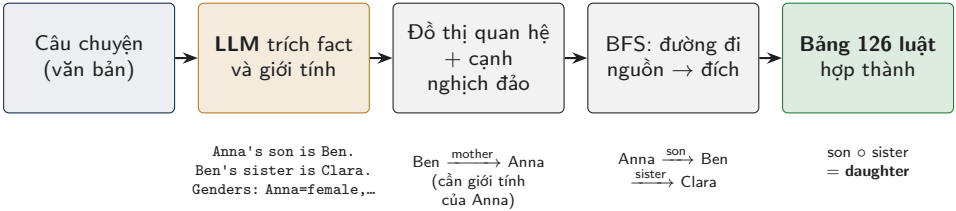
Ý tưởng: nếu distractor hại qua chuỗi (R4), hãy bỏ chúng *trước* khi mô hình viết. Bộ chọn: attention hiệu chỉnh kiểu ICR (top-4 hoặc xếp lại thứ tự), hoặc để mô hình tự chọn.

Dist.	Mô hình	CoT	SC_5	Top-4	Rerank	Tự chọn	Gold
4	1.5B	24.8	**28.4**	23.6	23.0	13.2	34.8
4	3B	38.8	**41.4**	33.8	37.4	29.6	48.6
8	1.5B	22.2	**25.0**	22.0	22.2	13.2	31.4
8	3B	31.6	**35.6**	27.4	33.6	24.8	45.6

EM (%), $n = 500$. "Gold" là trần lý thuyết (chỉ giữ đoạn đúng), không phải phương pháp.

- Có chỗ để cải thiện: trần Gold cao hơn CoT 9–14 điểm.
- Nhưng attention của mô hình $\leq$3B chọn chưa đủ chính xác: top-4 giữ đủ đoạn gold chỉ 77–86%, mất một đoạn gold là accuracy giảm một nửa.
- Self-consistency vẫn là baseline mạnh nhất. Kết luận: **KHÔNG HIỆU QUẢ**
- **Bug đã bắt được:** attention fp16 bị tràn số làm "top-4" luôn là 4 đoạn đầu (500/500 câu); đã sửa và chạy lại, số 7B bị loại.

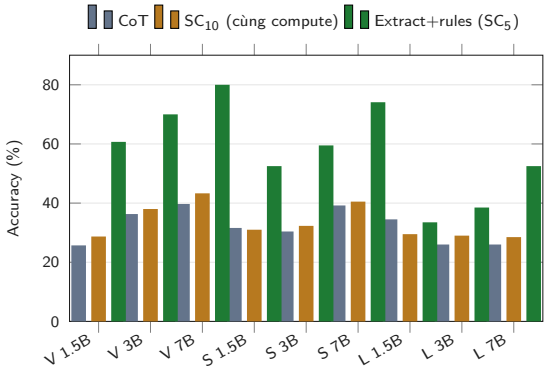
D2 · Đưa phép hợp thành ra ngoài mô hình: pipeline Extract + rules



Ý tưởng: R3 cho thấy mô hình *đọc* tốt nhưng *không hợp thành*. Vậy để mô hình chỉ làm phần nó giỏi (trích fact), giao phép hợp thành cho bảng luật. Về nhân quả, đây là *thực thi* structural equation của đồ thị suy luận.

Chi tiết: bảng luật tự induce từ tập train (126 luật, đúng 95% trên chuỗi gold); nếu không có đường đi thì quay về CoT; SC_5 cho bước trích fact. Baseline cùng compute: SC_{10}.

D2 · Kết quả: hơn self-consistency cùng compute +21 đến +37 điểm



V: validation, chuỗi 2–4 bước; S: task chưa thấy, 2–4 bước; L: task chưa thấy, **5–8 bước** (mô hình chỉ gặp chuỗi ≤ 4 lúc phát triển).

		Δ [CI 95%]
V	1.5B/3B/7B	+32.0/+32.0/+36.7
S	1.5B/3B/7B	+20.9/+27.2/+33.5
L	1.5B	−1.0 (n.s.)
L	3B	+9.5 [3.5, 15.5]
L	7B	+**24.0** [17.0, 31.5]

- Dòng L, 7B là kiểm định chính đăng ký trước: **THÀNH CÔNG**
- Chuỗi dài ở 1.5B không tăng vì trích sót fact: thiếu một cạnh là không tìm được đường đi.

D3 · Ablation nhân quả: mô hình có đủ thông tin nhưng không tự hợp thành được

Câu hỏi: mức tăng ở D2 có thể chỉ vì việc "trích fact" giúp sắp xếp thông tin?

Thiết kế: giữ *nguyên* các fact mà mô hình đã trích, chỉ đổi *bên làm phép hợp thành*:

- **LLM hợp thành**: đưa lại các fact đó cho chính mô hình.
- **Luật hợp thành**: bảng luật như D2.

Input giống hệt nhau, chỉ cơ chế tính đáp án khác nhau.

Chuỗi	Mô hình	CoT	LLM	Luật	Luật−LLM
2–4	1.5B	31.6	32.9	46.2	+13.3
	3B	30.4	28.5	54.4	+25.9
	7B	39.2	36.1	71.5	+35.4
5–8	1.5B	34.5	29.0	33.0	+4.0 n.s.
	3B	26.0	27.0	32.0	+5.0 n.s.
	7B	26.0	33.0	46.0	+13.0

Kết luận

Được đưa đúng các fact mình vừa viết, LLM vẫn chỉ ≈ CoT; bảng luật trên *cùng* các fact đó cao hơn 13–35 điểm. Vậy mức tăng đến từ **bước hợp thành**, không phải bước trích fact: đúng như R3 chẩn đoán. Đây là bằng chứng can thiệp khép vòng giữa chẩn đoán và hành động.

Đang chạy · Dạy mô hình tự làm phép hợp thành: structured-chain SFT

Câu hỏi thực dụng: D2 dựa vào bảng luật nên *rule-based* và chỉ đúng ở miền đóng. Có thể *dạy* chính mô hình làm việc đó không?

Ý tưởng: sau mỗi hop, ghi thêm một dòng "quan hệ tích luỹ": mỗi bước chỉ còn là tra cứu hai quan hệ (việc mô hình nhỏ làm được), và đáp án cuối là bản sao dòng cuối.

Ví dụ chuỗi có cấu trúc

```
Hop 1: Mabel's son is Rupert. ⇒ Rupert
So Rupert is Mabel's son.
Hop 2: Rupert's sister is Agatha. ⇒ Agatha
So Agatha is Mabel's daughter.
Answer: Agatha is Mabel's daughter.
```

Nhánh	Nội dung
P1	mô hình gốc, few-shot có dòng tích luỹ (không huấn luyện)
S_plain	LoRA trên chuỗi gold thường
S_struct	LoRA trên chuỗi có dòng tích luỹ

Đã có (P1): chỉ ra lệnh trong prompt **không giúp**: độ chính xác từng bước chỉ 12–18%, accuracy 23–28% (ngang CoT thường). Các nhánh huấn luyện ĐANG CHẠY

Tiêu chí đăng ký trước: trên chuỗi 5–8 bước, S_struct (3B) hơn baseline tốt nhất ≥ 2 điểm với CI > 0; nếu không, kết luận cấu trúc chuỗi không thêm gì so với fine-tune thường.

Hạn chế và những chỗ đã tự sửa

Hạn chế

1. Bảng luật dùng nhãn train mà CoT thường không thấy: cần đối chứng fine-tune cùng dữ liệu và rules-in-prompt.
2. CLUTRR là miền đóng, tổng hợp; chưa chứng minh trên văn bản thật.
3. Extract + rules gần Faithful CoT / Logic-LM: đóng góp mới nằm ở chẩn đoán và ablation nhân quả.
4. Mỗi ô 158–500 câu, đa số một seed; $T_{\text{copy-wrong}}$ chỉ 24–44 câu.
5. DRG dựa string match: chỉ 25–36% chuỗi liên thông.
6. Chỉ hai miền; chưa kết luận gì cho math hay code; chưa chạy mô hình >7B.

Claim cũ	**Đã sửa thành**
Distractor làm CoT mất ≈ 10 điểm (pilot 120 câu)	$n = 500$: 3–6 điểm
"CoT dễ tổn thương hơn Direct"	không có ý nghĩa, bỏ claim
Calibration là đóng góp phương pháp	≈ sinh tự do, chỉ là baseline
Attention top-4 trên 1.5B	bug fp16, đã sửa; loại số 7B
Extract không giới tính +6–8 điểm	post hoc, xác nhận thất bại; chỉ báo cáo bản đăng ký trước

Kết luận: chứng minh được gì, chưa chứng minh được gì

Chứng minh được

1. Hai cách đo "step importance" phổ biến (xoá một bước; resampling baseline cố định) **lệch có hệ thống**, có công thức đóng và được xác nhận (R1, R2).
2. Mô hình 0.5B–7B **đọc** chứ không **suy luận qua** chuỗi; $\leq$3B chép cả đáp án sai mà nó tự giải được (R3).
3. Tác hại của distractor đi qua chuỗi được sinh lại (R4), nên decoding ở bước đọc không sửa được (R5).
4. Thực thi phép hợp thành ngoài mô hình tăng accuracy rất lớn, và ablation chứng minh bước hợp thành là nguyên nhân (D2, D3).

Chưa chứng minh được

- Một phương pháp *decoding token* mới vượt self-consistency: HGCD, CAD, calibration, lọc bằng attention đều không đạt.
- Extract + rules mới đúng ở miền có luật đóng (CLUTRR).
- Mô hình học được phép hợp thành qua dữ liệu có cấu trúc (đang chạy).
- Công thức có tổng quát sang văn bản thật (kế hoạch).

Thông điệp

Mô hình nhỏ *đọc* chuỗi chứ không *suy luận qua* chuỗi. Vì vậy chỉnh cách chọn token không giúp được; muốn trả lời đúng hơn phải **can thiệp vào chỗ bị hỏng**: cấu trúc chuỗi và bước hợp thành.

Hướng tiếp theo

#	Việc cần làm	Mục đích
1	Chạy xong structured-chain SFT (CLUTRR, 2 seed); đối chứng fine-tune thường	biết cấu trúc chuỗi có thêm gì so với fine-tune cùng dữ liệu
2	Baseline rules-in-prompt cho CLUTRR	loại bỏ phản biện "bảng luật là thông tin mô hình không thấy"
3	Kiểm tra tổng quát: MuSiQue và 2WikiMultihopQA (huấn luyện chuỗi có trích dẫn đoạn nguồn)	chứng minh tính ứng dụng trên văn bản thật
4	Nếu có tín hiệu: constrained decoding theo bảng luật hoặc DPO với cặp phản thực (chép đáp án sai vs hợp thành đúng)	phiên bản "decoding đúng nghĩa" và đo mô hình có biết bác bỏ tri thức sai
5	Mô hình lớn hơn (14B, OLMo-2) và dữ liệu thật của người dùng	kiểm tra quy mô và ứng dụng

Nói thẳng về mức độ tin cậy của việc 3

Khả năng thắng trên MuSiQue ở mức trung bình-thấp (không có phép hợp thành thật sự, chỉ là tra cứu cầu nối); 2WikiMultihop có cơ hội tốt hơn. Nếu thua, ta biết rõ giới hạn là miền có luật đóng. Code đã sẵn sàng (`hgcd/egen.py`) nhưng *chưa chạy*.

XIN TRÂN TRỌNG CẢM ƠN!

Câu hỏi và thảo luận

Phụ lục · Thuật ngữ

CoT	chain-of-thought: chuỗi suy luận từng bước mô hình viết ra trước khi trả lời.
Hop	một bước trong chuỗi, dạng `Hop i: nội dung` ⇒ `kết quả`.
DRG	đồ thị suy luận có hướng: nối bước $i \to j$ nếu kết quả của i được nhắc lại trong j.
$\mathrm{do}_{\mathrm{naive}}$, $\mathrm{do}_{\mathrm{total}}$	che một bước / che bước cùng các bước phụ thuộc.
Placebo, marker	control: viết lại cùng nghĩa / chèn `[MASKED]` nhưng giữ nội dung.
AUC	khả năng phân biệt bước cần thiết với bước thừa (0.5 là đoán mò).
PS = 1	câu hỏi mà mô hình tự giải đúng từ chuỗi gold.
TE / NDE / TIE	hiệu ứng tổng / trực tiếp (chuỗi cố định) / gián tiếp (qua chuỗi).
SC	self-consistency: sinh nhiều chuỗi, bỏ phiếu đa số; "cùng compute" nghĩa là baseline có ngân sách sinh không ít hơn.
HGCD, CAD	decoding ở bước đọc đáp án: khuếch đại hiệu ứng của chuỗi / tương phản có và không có ngữ cảnh.
Calibration	trừ phần thiên lệch của mô hình khi không có nội dung.
Go/no-go	ngưỡng thành công ghi trước khi chạy.
LoRA	fine-tune nhẹ bằng các ma trận hạng thấp.
Rules-in-prompt	đưa bảng luật vào prompt thay vì thực thi ngoài mô hình.

Phụ lục · Nguồn số liệu và vị trí file

Nội dung	Đường dẫn trong repo (nhánh `claude/funny-cori-rt5wrv`)
Paper tiếng Anh / báo cáo tiếng Việt chi tiết	`paper/main.pdf`, `paper/baocao_vi.pdf`
Nhật ký giả thuyết đăng ký trước và go/no-go	`REVIEW.md`
R1–R3 (reliance)	`results/reliance_v2/`
R4 (mediation, $n = 500$)	`results/mediation_n500/`
R5 (HGCD)	`results/decoding/`
D1–D3 (decoding vòng 9)	`results/causaldec/` (C4, C5, C6: CLUTRR; C7_ablate; M_select*: MuSiQue)
Structured-chain SFT (đang chạy)	`hgcd/cftrain.py`, `results/cftrain/`
Kiểm tra tổng quát (chưa chạy)	`hgcd/egen.py`
Ghi chú nghiên cứu và nhật ký trao đổi	`docs/research_notes.md`, `docs/conversation_log.md`